

# 文献笔记

8.6–8.12

## 1. Influence Maximization with Novelty Decay in Social Networks

(1) 研究内容：在社交网络中找到一组种子节点，使得它们的影响传播在一定的传播模型下最大化

(2) 创新点及要点：

- 考虑新颖性衰减（重复曝光对用户的影响会减弱。对一个故事的多次曝光只会略微增加在社交网络中投票支持它的概率）对影响传播的影响，即研究具有新颖性衰减 (IMND) 的影响最大化问题
- 开发了一个拟合函数来表征效果，从而能够将新颖性衰减因子集成到独立级联 (IC) 等影响传播模型中。与传统的影响传播模型不同，新的影响函数既不是单调的，也不是次模的。这使得几乎所有现有使用 CELF 优化的贪心算法的影响最大化算法不适用。通过改编 U-Greedy(解决社交网络中的利润最大化问题（具有非单调性和子模块性）而开发的) 算法以动态方式处理低影响力节点。
- 由于影响传播的方式随着每对节点之间的延迟时间不同，计算影响传播变得复杂。开发了一种基于传播路径的算法来估计种子节点的影响传播。
- 具有新颖性衰减的 IC 模型：在具有时间延迟的 IC 模型中，每个节点都有两种状态：活跃和不活跃。允许从非活动状态切换到活动状态，反之则不行。对于社交网络中的每个节点，用表示为  $IC_{ND}$  的新颖性衰减来增强 IC 模型。
- R-Greedy 算法:IMND 问题寻求具有不大于  $K$  个节点 ( $|S| \leq K$ ) 的种子集。首先选择每个具有最大边际影响的前  $K$  个节点，然后选择具有最大影响散布的种子节点集。
- 动态剪枝优化: 利用先前的影响扩散计算来选择 R-Greedy 算法中的潜在种子节点
- 计算影响传播的算法: 开发一种基于传播路径的算法，该算法克服了基于仿真的技术的低效率 (算法耗时且不适合大型社交网络)。

## 2. Inf2vec: Latent Representation Model for Social Influence Embedding

(1) 研究内容：对社会影响力中的影响参数进行建模和研究。

(2) 创新点及要点：

- 与传统的估计社交网络中每个边的传播概率的方法不同 (由于数据稀疏性, 不能有效地学习所有边的传播参数), 引入了一种新的社会影响嵌入问题, 即学习节点而不是边的参数 (在低维潜在空间中表示社会影响传播)。节点在低维空间中被表示为向量, 因此社会影响信息可以通过这些向量来反映。
- 开发了一个新的模型 Inf2vec, 它结合了本地影响邻域和全球用户相似性来学习表征
- 不是直接估计每条边的传播概率, 而是试图学习每个节点的表征, 这样社会影响就被潜伏的低维空间中的节点表征所反映。优点:
  - 可以帮助有效地识别用户之间隐藏的影响关系 ( $u_1 \rightarrow u_3, u_2 \rightarrow u_3, u_4$  故  $u_1$  也可能影响  $u_3$ )。
  - 可以缓解稀疏的观察数据带来的挑战。(现有的模型不能有效地学习没有观察到的影响传播的边缘的概率。)
- 一个新的研究问题: 社会影响力嵌入。目的是将社会影响力传播有效地嵌入到一个低维的潜在空间中。(现有的关于学习影响力模型的工作都没有联合捕捉到影响力传播和网络嵌入, 且都没有考虑用户兴趣的相似性)
  - 需要对会影响用户在线行为的多种因素进行建模, 包括社会网络结构、过去的影响力传播和用户兴趣的相似性。
  - 根据稀疏的观察传播数据有效地学习节点的表征
  - 学习过程应能够大规模运用
- Inf2vec 模型的关键是如何从观察到的传播中生成影响力上下文 (只能观察到用户的行为, 但不知道谁确实受到了某个用户的影响), 也就是一组会被某个用户影响的用户
  - 采用本地影响力传播邻域。给定一个社会网络和一组行动观察, 提取一个传播网络, 并利用传播网络上的随机行走策略来产生一组用户。这些用户作为给定用户的本地影响背景。
  - 考虑用户兴趣的相似性。一个用户的行为不仅会受到他的朋友的影响, 也会受到用户的个人偏好的影响, 即具有相似兴趣的用户更有可能执行相同的行动。
  - 该算法创新之处在于产生了影响背景, 它结合了本地影响背景和全球用户相似性背景, 能够结合三个因素: 网络结构、影响力扩散和用户兴趣的相似性。
- 评估算法效果:
  - 激活预测, 即预测用户是否会受到他的朋友的影响
  - 扩散预测, 给定一组种子用户, 尝试识别受他们影响的用户
  - 可视化, 将学习表示通过降维工具进行降维

### 3.HME: A Hyperbolic Metric Embedding Approach for Next-POI Recommendation

- (1) 研究内容: 基于位置感知社交媒体服务, 对用户下一个兴趣点 (POI) 进行推荐, 其目的是根据用户的当前位置为用户推荐未来几个小时内要访问的 POI。关键难点在于从稀疏的签到数据中精确学习用户的连续运动。
- (2) 创新点及要点:

- 将数据投影至双曲空间中建模而非欧几里得空间
  - 欧几里得空间中的嵌入方法学习复杂模式的能力 (特别是层次结构), 受到欧氏空间维度的限制。
  - 双曲空间中签到活动的表征可以有效地捕捉由用户运动的幂律分布 (大多数节点有非常少的连接, 而少数节点有大量的连接) 所暗示的潜在的层次结构。
  - 双曲空间中签到活动的表征提供了很高的代表性, 使签到数据在低维空间中得到有效的表示。
  - 双曲空间可以有效地捕捉树状结构, 因为树可以近似地被看作是双曲空间的离散版本 (树状结构中的子数随着与根的距离呈指数增长, 而双曲空间也随着半径的增长呈指数增长)。
  - 双曲空间能够在低维空间中对复杂数据进行建模, 因为双曲空间随着半径的扩大而呈指数级增长, 而欧几里得空间只呈多项式增长
- 开发了一种新的双曲度量嵌入 (HME) 方法学习 Poincaré 球模型中的潜在表征, 基本思想是用 Poincaré 球模型来表示项目, 球模型中的距离被用来反映项目之间的关系, 利用贝叶斯排名方法使得相关的项目比不相关的项目更接近。将四种不同的关系 (POI-POI, POI-User, POI-Category and POI-Region) 投射到一个共享的双曲空间中来共同学习。
- 开发了 Einstein midpoint aggregation 用于整合用户偏好和顺序转换的影响, 在 Poincaré 球模型中结合用户的偏好和 POI 的顺序转换。同时考虑地理距离因素 (用户倾向于访问靠近他们当前位置的 POI)。
- 在三个真实世界的签到数据集上进行实验, 证明了双曲度量嵌入相对于传统的基于欧几里得的嵌入方法的明显改进 (双曲表征在低维空间的优势)。
- 在另外四个在线交易数据集上进行了 next-item recommendation 的推荐实验, 以进一步证明我们提出的方法的通用性
- 双曲空间是恒定负曲率的空间, 而欧几里得空间的曲率为零。因此, 双曲空间表现出指数扩展特性。优势:
  - 可以有效地模拟分层结构
  - 能以小维度对复杂数据进行建模, 从而减少表示模型中的参数数量
- 在一个双曲空间中对签到活动进行建模。该问题表述如下:
  - 用户移动性的双曲表示 (双曲度量嵌入):
    - \* 用庞加莱球模型表示项目, 使得相关项目彼此接近
    - \* 利用庞加莱球模型中的距离来测量节点的接近度
    - \* 利用贝叶斯个性化排名 (BPR) 方法来学习训练对的可能性
    - \* 由于庞加莱球的黎曼流形结构, 不能直接使用随机梯度下降 (SGD)。应首先计算欧几里得梯度, 然后将它们与黎曼梯度结合起来更新参数。
  - Next-POI 的推荐
    - \* 需要计算与查询  $(u, l_c)$  密切相关的 POI 列表, 即与查询距离最短的那些 POI

- \* 由于用户偏好和顺序转换对于下一个 POI 推荐都很重要，因此我们需要通过计算  $u$  和  $l_c$  的聚合来结合这两个因素
- \* 由于双曲几何，不能简单地在庞加莱球模型中应用两点的线性插值。
- \* 采用 Klein 模型中的 Einstein 中点聚合
- \* 由于 Poincaré 模型和 Klein 模型用不同的坐标来描述同一个双曲空间。因此，首先将庞加莱球坐标转换为克莱因坐标，然后计算聚合点。之后，将克莱因坐标转移回庞加莱球模型
- 评估双曲度量嵌入模型的性能的指标：
  - 顺序转换: 给定一个位置，预测最有可能的连续位置。
  - Next-POI 推荐: 建议用户接下来签到的 POI 列表。
  - Next-Item 推荐: 根据用户购买的最后一个项目为用户推荐下一个购买的产品 (证明模型可以应用于其他领域)

#### 4. Node2LV: Squared Lorentzian Representations for Node Proximity

(1) 研究内容: 提出了一个名为 Node2LV 的网络嵌入模型, 从而代替现有的双曲线嵌入模型

(2) 创新点及要点:

- 提出了一个名为 Node2LV 的新嵌入模型，该模型使用平方洛伦兹距离来学习节点的双曲线表示 (现有的双曲线模型仅捕获节点之间的一阶接近度)。
  - 模型可以有效地捕获来自网络拓扑的层次结构
  - 与计算复杂的黎曼梯度的传统双曲嵌入方法相比，可以以更有效的方式进行优化
  - 与现有的双曲线嵌入模型不同，Node2LV 捕获了高阶近似。
- 两个双曲线嵌入表示每个节点，并使相关节点的嵌入彼此接近。为了保持高阶节点的邻近性，使用随机游走策略来生成局部邻域上下文。
- 现有的双曲线嵌入模型的限制：
  - 现有的双曲线嵌入模型主要适用于层次明确的树形数据集，而现实世界中的图仅在某种程度上表现出树状属性，但这些图中没有明确的层次定义
  - 现有的双曲嵌入模型只保留了一阶邻域关系，而高阶邻域对于捕捉节点的接近性和提高网络嵌入的质量非常重要
  - 现有的双曲嵌入模型通常利用黎曼梯度法来学习节点表征，在计算上较为复杂
- 提出了一个新的双曲网络嵌入模型 (Node2LV) 来学习节点的表征
  - 利用了洛伦兹距离的平方，能够更有效的捕捉到层次结构 (节点度遵循幂律分布) 和高阶节点的接近性
  - 将每个节点与双曲空间中的两个向量相关联：一个表示其影响其他节点的能力的源向量，以及一个反映被其他节点影响的可能性的目标向量。
  - 为了保持高阶的接近性，探索了更广泛的邻域环境，从而提高了嵌入的质量。
  - 通过高效的欧氏随机梯度下降法 (SGD) 来训练，以减少训练时间。

- 评估任务:
  - 链路预测: 期望一种好的网络嵌入方法具有良好的泛化能力来推断未知链路
  - 节点推荐: 尝试为给定的节点推荐接近度得分最高的前 k 名候选对象

## 5. POI2Vec: Geographical Latent Representation for Predicting Future Visitors

(1) 研究内容: 预测用户在给定的未来一段时间内会访问一个给定的 POI

(2) 创新点及要点:

- 提出了一个新的潜在表征模型 POI2Vec 以纳入地理影响 (在用户移动行为建模中非常重要)
- 提出了一种方法来联合建立用户偏好和 POI 顺序转换影响的模型, 以预测给定 POI 的潜在访问者
- 现有的 word2vec 技术的限制:
  - 未能在 word2vec 模型中纳入 POI 的地理影响, 即用户倾向于访问附近的 POI
  - 分别对顺序转换和用户偏好进行建模。(由于每个签到行为都与顺序转换和用户偏好有关, 因此对这两个因素进行联合建模更为合理)
- POI2Vec 模型 (在 word2vec 框架内纳入地理影响的工作):
  - 每个 POI 被表示为潜在低维空间中的一个向量, 两个向量的内积反映了两个 POI 之间的关联性
  - 利用了分层 softmax (HS) 技术, 开发了一种新的二叉树构建方法, 能够纳入 POI 的地理坐标。(将 POI 分层分成不同的区域, 然后在每个区域的 POI 上构建二叉树。由于一个 POI 也可能影响到相邻区域的 POI, 将一个 POI 分配到多个附近区域)
  - 对用户的偏好进行建模, 其中每个用户也用一個潜在的向量表示。提出了一个模型, 通过考虑用户偏好和顺序转换, 共同学习用户和 POI 的潜在表示。
  - 同时考虑有最近位置的用户和最近位置未知的用户来预测一个兴趣点的潜在访问者
- 与传统的 POI 推荐研究不同点:
  - 为一个 POI 寻找未来几个小时的潜在访客, 而非为访客推荐未来的 POI
  - 使用潜在表示算法来共同学习用户的偏好和顺序转换
- POI2Vec 方法与传统的 Huffman 树结构相比有两个优点:
  - 考虑 POI 在构建二叉树过程中的地理因素的影响
  - 在 POI2Vec 模型中, 一个 POI 在二叉树中可能出现多次, 而在常规模型中, 每个 POI 只出现一次。
- 评估任务:
  - 评估下一个 POI 预测任务中顺序转换的潜在表示的质量。
  - 评估未来访客预测的准确性。

## 6.GETNext: Trajectory Flow Map Enhanced Transformer for Next POI Recommendation

(1) 研究内容：根据用户的当前状态和历史信息预测用户近期的移动

(2) 创新点及要点：

- next-POI 推荐更注重近期轨迹的时间影响，以预测用户的下一步行动
- 提出了一种与用户无关的全局轨迹流图和一种新颖的图形增强型 transformer 模型 (GET-Next)，以更好地利用广泛的协作信号（来自其他用户）来进行更准确的下一个 POI 预测，同时缓解冷启动问题。
- GETNext 将全局转换模式、用户的一般偏好、时空上下文和时间感知类别嵌入结合到一个 transformer 模型中，以预测用户的未来移动。
- 原有的采用各种形式的递归神经网络 (RNN) 来编码时空信息的方法的局限：
  - 由于短轨迹提供的有限时空背景，短轨迹上的模型性能与长轨迹相比显著下降
  - 冷启动问题：只签入少量 POI 的非活跃用户的推荐准确率通常较低。在现实生活中的推荐系统中存在冷启动问题较为常见
  - 现有模型无法弥合时间和 POI 类别。而 POI 类别通常呈现出很强的时间相关性（与午夜相比，高峰时段火车站的签到频率显著高于午夜。）。
- 解决问题的思路：通过利用其他用户的集体信息，可以在一定程度上缓解由于固有的数据稀缺问题带来的限制。特别是，个人倾向于共享某些签到序列的片段，形成集体轨迹流。
- next-POI 推荐中利用这些轨迹流的问题及解决方案：
  - 如何聚合来自签到序列的信息以形成全局轨迹流模式的统一表示？
    - \* 构建了一个新颖的（与用户无关的）轨迹流图，它在单个图形结构中总结了 POI 之间的轨迹以及每个 POI 的特征。
    - \* 图中的节点是具有包括地理位置、类别和签到次数在内的属性的 POI。如果在同一签入轨迹中连续访问它们，则有向边将 POI 连接到另一个 POI，边权重表示它们的共访问频率。
    - \* 该轨迹流程图捕获了 POI 之间的过渡影响。通过使用图卷积网络（GCN）将 POI 嵌入到潜在空间（该潜在空间保留了 POI 之间的全局转换），从而利用轨迹流图中的集体信息
    - \* 即 GCN 通过聚合其邻居的嵌入来更新每个节点的嵌入。从而使每个 POI 在轨迹流图中的嵌入都会受到其先例的影响，从而保留全局转换的信息。
    - \* 全局轨迹流图背后的一个基本假设是，推荐的 next-POI 可能不是最佳选择，但肯定会从随机猜测中得到改进。
  - 除轨迹流，如何保留类别信息、用户偏好等重要的时空上下文信息？
    - \* 利用嵌入层来捕捉用户的长期偏好，POI 类别嵌入和一个 time2vec 模型来描述时间嵌入（即由用户最近的签到反映的短期偏好）。

- \* 由于 POI 类别通常与时间有很强的相关性，可将类别和时间嵌入融合到一个融合模块中，生成具有时间感知的类别上下文嵌入。
- 如何在 next-POI 推荐中利用以上所有信息，在通用运动模式和个性化需求之间取得平衡？
  - \* 提出了一个图形增强 transformer 框架 GETNext，该框架统一了通用的运动模式、用户的一般偏好、短期的时空内容变化以及时间感知的类别嵌入来预测用户的下一个 POI。
  - \* 在 GETNext 中，采用带有多个多层感知器 (MLP) 解码器的转换器编码器来集成在 POI 嵌入和其他个性化嵌入中编码的隐式全局流模式
- 主要贡献：
  - 提出了一个全局轨迹流图来模拟常见的访问顺序转换信息，并利用图卷积网络将它们编码为 POI 嵌入。
  - 开发了一个新的时间感知的类别上下文嵌入，以捕捉 POI 类别的不同时间模式。
  - 提出了一个基于变换器的框架，将全局过渡模式、用户的一般口味 (长期偏好)、用户的短期轨迹和时空背景整合在一起，用于推荐 next-POI。

### (3) 未来工作：

- 进一步探索和区分时间模式，例如工作日和周末之间
- 根据用户的行为对用户进行分类，并为每种类型的用户构建轨迹流图

## 7.Hierarchical Multi-Task Graph Recurrent Network for Next POI Recommendation

(1) 研究内容：用户接下来将访问哪个兴趣点 (POI)，为每个用户预测一个排名的 POI 集

(2) 创新点及要点：

- 提出了分层多任务图递归网络 (HMT-GRN) 方法，该方法通过在多任务设置中学习不同的低稀疏用户区域矩阵来缓解数据稀疏问题。
- 对不同的区域和 POI 分布执行分层波束搜索 (HBS)，以随着空间粒度的增加分层减少搜索空间并预测下一个 POI。本文的 HBS 通过减少搜索空间来提高效率
- 提出了一种新颖的选择性层来预测用户之前是否访问过下一个 POI，以在个性化和探索之间取得平衡。
- 现有工作中的问题是 User-POI 矩阵的高度稀疏性 (因为用户通常只会访问作为搜索空间的数据集中所有 POI 中的几个首选 POI)，这使得学习和准确预测用户未来将访问的下一个 POI 变得困难。
- 提出了一种分层多任务图循环网络 (HMT-GRN) 来学习用户-兴趣点矩阵，同时也学习了几个不同粒度级别的用户-区域矩阵，以更好地学习稀疏的用户-兴趣点关系。
- 提出了 HMT-GRN 模型，以多任务学习的形式学习 User-POI 和 User-G@P 矩阵，预测下一个 POI 和 G@P 区域，然后执行 Hierarchical Beam 对学习到的任务分布进行搜索 (HBS)，以分层减少搜索空间并提高预测下一个 POI 的效率

- 提出了一个选择性层来预测下一个 POI 是历史访问过的 POI，还是用户未访问过的 POI，从而分别执行个性化和探索，从而在个性化和探索之间取得平衡
- 提出了图形递归网络（GRN）模块，通过考虑 POI-region 和 POI-timeslot 关系的空间和时间图，同时学习 POI 访问序列中的顺序依赖性和全局时空 POI-POI 关系，以缓解稀疏性。

(3) 未来工作：探索时间集中的任务，以帮助进一步减少数据稀疏性

## 8. Next Point-of-Interest Recommendation with Auto-Correlation Enhanced Multi-Modal Transformer Network.

(1) 研究内容：下一个兴趣点 (POI) 推荐

(2) 创新点及要点：

- 已有的基于递归神经网络的下一个 POI 推荐算法的问题：
  - 大多数模型只考虑连续访问的依赖关系，而忽略了 POI 在痕迹中错综复杂的依赖性
  - POI 序列中分层的性质和子序列的匹配在现有方法中很难建模
  - 大多数的解决方案都忽略了 POI 与密度类别这两个模型之间的相互作用
- 为 next-POI 推荐提出了一种自相关的增强型多模态 Transformer 网络（AutoMTN）。特别是，AutoMTN 使用 Transformer 网络显式地利用跟踪中所有 POI 的连接。
- 发现子序列级别的依赖关系并关注 POI 和类别序列之间的跨模态交互，将 Transformer 中的 self-attention 替换为自相关机制，并设计了一个多模态网络。
  - POI 的类别和位置之间的交互很重要，因为下一个位置受类别影响
  - 由于该模型无法学习类别的信息。为了预测下一个用户类别以支持下一个用户 POI 的预测，设计了一个双通道 Transformer 网络来分别预测 POI 和类别。
  - 将 Transformer 网络中的自注意机制替换为基于序列周期性的自相关机制，以增强双通道 Transformer 网络，该网络可以发现子序列级别的依赖关系和聚合表示
  - 模型的核心是定向跨模态自相关，关注 POI 和类别序列之间跨不同时间步长的交互，并潜在地将子序列的信息从一种模态调整到另一种模态
- 基于 RNN 架构的方法推荐 POI 存在的问题：
  - 在短期连续访问方面受到限制，即它们几乎无法模拟时间线上很远的访问之间的隐式连接
  - 忽略了子序列的重要影响，这超出了 POI 级别的序列模式
  - 无法捕捉到 POI 和类别之间的跨模态知识，而 POI 的类别和位置之间的交互很重要，因为下一个位置受类别影响
- 本文的主要贡献：
  - 第一个利用多模态 Transformer 网络获得 POI 和类别序列之间的交叉模态信息



- 利用多模态 Transformer 网络中的自相关机制来学习子序列模式
- 自相关层:
  - 由于以前的方法基于循环结构，总是忽略不连续访问的信息，故无法在子序列级别提取相关性
  - 利用自相关机制通过子序列关系来扩展信息利用，即通过计算子序列的自相关来发现子序列的依赖关系，并通过时间延迟聚合来聚合相似的子序列。

## 9.Next Point-of-Interest Recommendation with Inferring Multi-step Future Preferences

(1) 研究内容：考虑未来行为对选择 next-POI 决策的影响，即因为用户可能经常会考虑活动计划，用户的下一次 POI 访问也可能会受到他们未来多步骤行为的影响。

(2) 创新点及要点：

- 提出了一种新颖的上下文感知的未来偏好推理推荐器 (CFPRec)，以自我组合的方式帮助推断用户的未来偏好
  - 由于用户每日签到的周期性特征，从学习到的过去偏好中巧妙地推导出多步骤的未来偏好，从而隐含地模仿用户在下次访问前的活动计划
  - 推断出的未来偏好与当前偏好无缝整合，以实现更具表现力的用户偏好学习
- 关于 CFPRec:
  - 由过去和当前的偏好编码器以及未来偏好提取器组成
  - 采用了 Transformer 层和 LSTM 层分别对用户的过去和当前偏好进行建模
  - 设计了三个辅助目标来监督过去偏好的学习。用户日常签到行为的周期性属性，促使设计了通过自我组合方式进行隐式未来偏好推断的提取器，即多步骤的未来偏好是通过两层注意力聚合从学习到的过去偏好中提取的，减轻了缺乏明确未来行为的挑战
  - CFPRec 为下一个 POI 的预测编码了左边和右边的环境（即过去/现在和未来的偏好）
- 主要贡献:
  - 第一个研究多步骤的未来偏好在下一个 POI 推荐中的影响
  - CFPRec 联合模拟了用户过去、现在和未来的连续行为，以获得更具表现力的偏好表示。特别是，设计了一个未来偏好提取器，以自我组合的方式从学习的过去偏好中推断出隐含的未来偏好
- CFPRec 的框架:
  - 过去的偏好编码器，对用户过去的长期轨迹进行建模，以捕捉非连续签到行为之间的上下文感知相关性
    - \* 双向 Transformer 作为过去的偏好编码器

- \* 在模型训练过程中, Transformer 编码器能够对目标 POI 的左右上下文进行建模, 从而能够学习到更具表现力的 POI 表征
- \* 在捕捉非连续签到之间的上下文关联性和在轨迹中自动聚合最相关的行为方面显示出强大的能力
- 当前偏好编码器, 通过对最近的顺序签到建模来学习用户当前的偏好
  - \* 采用一个 LSTM 单元, 从当前的签到行为中表征用户的时间意识的顺序依赖性
- 未来偏好提取器, 配备两层注意力聚合, 用于推断多步未来偏好
  - \* 用户日常签到行为的周期性特性启发作者推导出一个提取器, 该提取器配备两层注意力聚合, 以自集成的方式推断多步隐式未来偏好, 从而隐式模仿用户下次访问前的活动计划
- 实验所研究的问题:
  - CFPRec 是否优于最先进的 baseline?
  - CFPRec 的不同组件如何影响其性能?
  - CFPRec 的关键超参数如何影响其性能?

## 10. Empowering Next POI Recommendation with Multi-Relational Modeling

(1) 研究内容: 考虑关系异质性 (relational heterogeneities) 对 next-POI 推荐的影响

(2) 创新点及要点:

- 提出了一个新的框架 MEMO, 有效地利用了多网络表示学习模块的异构关系, 并明确地将跨时的 user-POI 的相互影响与耦合的递归神经网络结合起来。
- 目前关于 LBSN 的 POI 推荐存在的问题:
  - 社会关系的异质性 (由于用户的偏好经常与不同类型的社会关系有着密切的联系, 故而不同的社会关系对用户的影响是不同的), 再加上用户对 POI 的访问形成的 user-POI 关系, 给有效利用嵌入的丰富信息带来了巨大挑战
  - 捕捉用户和兴趣点之间关键的、跨时空的相互影响仍然具有挑战性 (用户的偏好和 POI 的潜在状态 (如声誉) 会随着时间的推移相互影响)
- 关系模型 (MEMO) :
  - 开发了一个基于多图卷积网络 (GCNs) 和 self-attention 的多关系建模模块, 从而利用不同的 user-user 社会关系和 user-POI 关系 (异构关系)
    - \* 将每一种关系映射到相应的网络, 以学习特定的关系表征; 然后采用 self-attention 机制, 从不同的关系类型中聚合用户表征
  - 设计了一个基于耦合的递归神经网络 (RNN) 的 user-POI 相互影响建模组件相互更新对方的表征, 从而捕捉用户和 POI 之间随时间推移的相互影响
- 本文的贡献:
  - 模型考虑了关键的、但被忽视的异质关系, 特别是用户之间的异质社会关系, 以及用户与 POI 之间的跨时空相互影响

- 提出了一个新的框架 MEMO，通过多网络表征学习模块纳入异质关系，并通过耦合的 RNNs 捕捉用户与 POI 之间的相互影响
- 实验研究内容：
  - 比较了不同方法 next-POI 推荐的性能
  - 消融研究以调查不同模型组件的贡献
  - 评估框架的稳健性

## 11. TADSAM: A Time-Aware Dynamic Self-Attention Model for Next Point-of-Interest Recommendation

(1) 研究内容：考虑 next-POI 推荐中用户访问的时间因素，即预测用户何时做出下一步决定（在下一个 POI 推荐中，预测用户何时去）

(2) 创新点及要点：

- 目前面临的问题：
  - 随着时间的变化，用户的历史行为表现出多样性和复杂性
  - 由于用户轨迹数据的稀疏性，难以捕捉到用户在相应时间模式下的偏好
- 提出了一个时间感知的动态 self-attention 模型 TADSAM 来预测用户在未来的下一步决策活动
  - 使用一个扩展的 self-attention 机制来处理用户复杂的签到记录
  - 考虑到时间的影响，将用户的签到记录分为不同的时间窗口，并开发了一种个性化的权重计算方法，以利用用户行为的时间模式
- 传统的 POI 推荐是根据用户的一般静态偏好向用户推荐合适的 POI，而忽略了最近的访问。相反，next-POI 推荐是根据用户的当前位置和以前的访问信息来确定用户的下一个决策活动
- self-attention 模型：具有强大的并行计算能力，能捕捉到长序列的依赖性
- TADSAM:
  - 使用多头注意力机制在签到序列之间进行转换
  - 使用用户轨迹的相对时间矩阵来扩展虚构的自我注意机制，从而考虑时间背景的影响
  - 将用户的历史签到记录划分为不同的时间窗口，并使用个性化的权重计算方法来获得用户的当前偏好，从而更好地探索用户历史轨迹序列的行为模式
- 本文的贡献：
  - 提出了一种时间感知的动态 self-attention 网络方法，使用一个相对的时间矩阵来扩展 vanilla self-attention 机制，以探索用户签到记录之间的关系。从而不仅可以探索用户复杂多样的行为模式，还可以了解用户的兴趣变化
  - 将用户的历史签到序列划分为不同的时间窗口，并设计出个性化的权重计算方法，以便更有效地探索用户行为的时间模式

- 结合 POI 的流程度和地理影响来提高系统的性能，以克服数据稀少的问题
- 实验评估任务：
  - TADSAM 与其他方法的性能比较
  - TADSAM 不同组件对性能的影响
  - 超参数的影响: 嵌入维度和 self-attention 块的数量
  - 分析过滤的影响

## 12.A survey on deep learning based Point-of-Interest (POI) recommendations

(1) 研究内容：对基于深度学习的 POI 推荐工作的综述

(2) 创新点及要点：

- POI 推荐技术本质上是利用用户的历史签到和其他多模态信息，来推荐下一组适合用户的 POI。
- POI 推荐的早期研究工作主要集中在特征工程和基于传统（非深度学习）机器学习的方法上，所有这些方法的一个主要缺点在于特征工程，而显式特征工程需要足够的领域专业知识。构建这些非结构化特征之间的关系并非易事。
- POI 推荐领域的主要难点：
  - 数据稀疏性: 集中描述用户和 POI 之间的关系的数据是稀疏的
  - 冷启动: 当一个用户加入 LBSN 网络时，由于缺乏对该用户的适当描述，导致初始推荐性能不佳。同样，当一个新的兴趣点被创建探索时，由于缺乏与该兴趣点相关的历史轨迹，它在推荐方面严重滞后于已有的兴趣点
  - 捕捉上下文信息: 准确的 POI 推荐依赖于处理 POI 特征以及用户评论和其他来自 LBSN 平台的文本数据，处理这些语义信息需要在 POI 推荐的主要神经网络的基础上增加额外的不同的嵌入层架构。
  - 用户偏好的变化: 一个用户可能在其生活方式上表现出很大的变化，从而表现出偏好的变化。
- 目前一些常用的神经网络及特点：
  - 前递网络：
    - \* 可以捕捉到特征中高度复杂的关系
    - \* 过高的表现力通常会导致训练数据的过度拟合
    - \* 随着层数的增加，模型的大小急剧增大，使得其更难训练和部署
    - \* 没有明确的空间和顺序特征处理能力，限制了其在时空模型中的应用
  - 卷积神经网络：
    - \* 适用于从给定的输入中捕捉空间特征
  - 递归神经网络：
    - \* 可以捕捉输入序列的上下文信息，即捕捉了序列模式
  - Long-Short Term Memory(LSTM):

- \* 可以捕捉长期偏好和短期偏好
  - \* 训练比较慢, 并且需要大量的训练数据
- 门控递归单元 (GRU):
  - \* 当训练数据较少时, 基于 GRU 的模型可以被更快地训练, 并且比 LSTM 表现更好
- Attention mechanism:
  - \* 通过模仿人类对突出的输入区域的关注, 解决在较长的序列中往往会失去特征, 导致模型性能不佳的问题。
  - \* 引入了 self-attention 机制, 这不仅提高了性能, 而且允许对输入进行并行处理, 在涉及顺序数据方面有潜力
- 生成式对抗网络 (GANs):
- POI recommendation models:
  - RNN based models
  - LSTM models
  - GRU models
  - Graph Embedding models
  - GAN models
  - other models
- 影响 POI 推荐的因素:
  - 顺序效应: POI 推荐的顺序效应, 上一个 POI 对下一个 POI 有一定的影响
  - 地理影响: 在某一区域内签到的用户, 有相对较大的概率去访问附近的地方
  - 语义影响: 每个兴趣点都有一些属性, 如果两个兴趣点有类似的属性, 那么它们在语义上就很接近。每个人都有自己的偏好, 一个人希望访问那些与其偏好相匹配的 POI。
  - 社会影响: 一个人的决定在很大程度上取决于其的社会地位、朋友、邻居、文化等。即朋友的评价等社会影响会影响一个人对访问一个景点的兴趣 (从而解决冷启动问题)
  - 时间上的影响: 一个用户一天中的不同时间段表现出不同的签到偏好, 而且在连续的时间段内往往比非连续的时间段有类似的偏好
- 未来的研究方向:
  - 准备基准数据集
    - \* 一个包含各种模式数据的基准数据集, 为评估不同模型的性能创造一个坚实的基础。
  - 为 LBSN 开发数据匿名化技术
    - \* 更加重视通过混淆用户身份来收集匿名的用户数据, 从而保护用户的隐私。
  - 融入在线学习

- \* 设计一个能够在新数据出现时更新模型的在线学习策略, 从而在不断变化的情况下, 模型也能长期提供最佳的推荐性能
- 开发保护隐私的 POI 推荐技术
  - \* POI 推荐技术可以利用一个新的保护隐私的学习领域, 即联合学习, 它不需要在任何中心站点积累用户数据。
- 为社会群体推荐 POI
  - \* 一个基于深度学习的社会群体 POI 推荐模型, 而非集中在个性化的 POI 推荐上

### 13. Conversation-Based Adaptive Relational Translation Method for Next POI Recommendation With Uncertain Check-Ins

(1) 研究内容: 通过与用户进行对话, 从而整合即时用户偏好以获得更准确的 next-POI 推荐

(2) 创新点及要点:

- 提出了一种基于对话的自适应关系翻译 (CART) 方法, 用于针对不确定签到的下一个 POI 推荐
- 有关 CART:
  - 配备了推荐器和对话模块, 以交互方式获取用户的即时偏好并进行动态推荐
    - \* 基于自适应关系翻译方法的推荐器通过对用户的历史顺序行为和从对话中接收到的即时偏好进行建模来执行位置预测
    - \* 对话模块旨在通过学习对话策略在更少的对话轮次中实现成功的推荐, 从而可以通过用户响应 (将会话中被拒绝的 POI 视为负样本) 更新推荐器
    - \* 设计了集体 POI 推荐成功的辅助奖励, 并在这样的集体 POI 内对个体 POI 选择采用了基于评分的抽样策略
  - 在用户-位置交互的严重数据稀疏的情况下 (过渡消失问题和极其稀疏的问题), 进行 next-POI 的推荐
- 现有的 next-POI 推荐所存在的问题:
  - 在现实中, 用户出于隐私考虑或室内导航的偏见并不总是披露某些特定签到 GPS (即用户可能会在一个集体的 POI 提供不确定的签到), 从而导致过渡消失的问题
  - 即大多数现有研究假设 POI 签到反映了用户的实际访问, 而真实情况可能会有部分 POI 签到丢失
  - 会话推荐系统 (CRS) 技术的发展, 它们允许推荐器获取用户的即时偏好并实时获得高质量的推荐对话, 为解决静态推荐器的局限性带来了前所未有的潜力
  - 静态推荐方法面临着这样一个内在的限制: 不能很好地捕捉到用户仅基于其历史行为的即时偏好, 因为其不能在静态模型设置中交互地阐明用户的当前偏好
- 主要贡献:
  - 研究了基于会话的下一个 POI 推荐任务, 其中包含不确定的签到, 突出了用户和系统之间的多轮对话在预测更准确的下一个 POI 方面的功效

- 基于自适应关系翻译的方法和 CRS 设计了 CART 框架。即 CART 由定制的推荐模块和对话模块组成，旨在模拟用户丰富的历史签到上下文和对话中的即时偏好，从而以更少的对话轮次实现成功的 next-POI 推荐。
- 注意，本文并不从头开始训练提出的 CART
  - 离线训练旨在在训练集上预训练推荐器和对话模块，其中最大熵策略用于确定要询问的属性
  - 在线训练阶段，通过训练集上的对话模块与用户模拟器交互，对预训练的 CRS 进行优化
- 实验评测：
  - CRS 方法的性能比较
  - 静态方法的性能比较
  - 用户反应质量研究
  - 消融实验
  - 超参数分析