

文献笔记

8.12-8.18

1.Learning Graph-based Disentangled Representations for Next POI Recommendation

(1) 研究内容：考虑 POI 的内在特征，即来自 POI 不同方面的特性对 next-POI 推荐的影响

(2) 创新点及要点：

- 提出了一种新型的 Disentangled Representation-enhanced Attention Network (DRAN):
 - 利用 Disentangled Representation 来明确地模拟不同方面和相应的影响，以更精确地表示一个 POI
 - 首先设计了一个传播规则，通过完善两种类型的 POI 关系图来学习基于图的分解表征，充分利用基于距离和过渡的影响来学习表征
 - 扩展了注意力架构，以聚合个性化的时空信息，为下一个时间戳上的动态用户偏好建模，同时保持分解表征的不同组成部分的独立性
- 作者认为先前纳入地理信息的方法未能对 POI 的复杂影响进行建模：
 - POI 对用户过渡的各种潜在影响没有被有效地分解开来
 - 基于距离的 POI 影响也被过度简化了 (没有考虑地形地貌而仅仅考虑距离)
- 把重点放在用 POI 表示法来增强序列建模方案，对潜在的方面和相应的影响有很强的表达能力
 - 提出了一种新型的纠缠表征增强注意网络 (DRAN)，用于 next-POI 推荐
 - 提出将每个 POI 的表示明确地分解为多个独立的组件，而不是直接在整体的 POI 嵌入中对纠缠的影响进行建模，每个组件都被用来表示单个方面和相应的影响
 - 提出了一种新的分解图卷积网络 (DGCN)，DGCN 学习了两种类型的分解表征，即基于过渡的和基于距离的分解表征
 - DGCN 通过细化全局 POI 关系图，充分利用了 POI 的图结构，避免了只考虑签到序列中的空间背景
 - 通过考虑个性化的时空信息来扩展 self-attention 机制，为用户的动态偏好建模，同时保持分解表示的每个组成部分的独立性
- 本文的贡献：

- 明确地分解 POI 的多个潜在方面，以捕捉相应的影响。提出了一个新的 DGCN, 在 next-POI 中首次尝试用分解表征学习来处理 POI 之间的复杂关联
- 提出了 DRAN，充分利用 POI 的全球影响和个人层面的动态偏好来完成下一个 POI 的推荐任务
- 不仅考虑 user-item 关系上，同时考虑底层的 item-item 关系，以在连续的数据中探索不同的用户意图
- DRAN 的整体架构:
 - 基于图的解耦表示建模模块, 利用新提出的 DGCN 层学习 POI 的解耦表示
 - 用户时空偏好建模模块，整合相关时空信息对用户历史签到序列进行建模
 - 预测和优化模块，估计用户偏好并优化所有可训练参数
- 实验研究内容:
 - 性能比较
 - 消融研究
 - 超参数研究
- 未来的研究：通过引入 POI 边信息来将潜在组件与 POI 属性耦合

2. Translating Human Mobility Forecasting through Natural Language Generation

(1) 研究内容：将 next-POI 预测视为翻译问题，并通过语言生成管道提出新的预测

(2) 创新点及要点：

- 旨在将人类流动性预测问题作为一项语言翻译任务，以序列到序列的方式来解决
 - 介绍了一个流动性到语言的模板，将数字流动性数据描述为自然语言句子。人类流动性预测翻译任务的核心直觉是将输入的流动性描述句子转化为未来的流动性描述，从中获得预测目标。在这个管道下，设计了一个双分支的网络，SHIFT（翻译人类流动性预测）
 - 包括一个用于语言生成的主分支和一个用于直接学习移动模式的辅助分支
 - 在训练过程中，开发了一种动力模式来更好地连接和训练这两个分支
- 神经机器翻译结构可能是解决以下限制的合适方案：
 - 当有多个语境时，连接操作可能不是合并不同数据源的最佳方式。当多个特征被附加在一起时，可能很难学习或捕捉到多个语境的潜在关联性。
 - 考虑到不同语境的固有特征，预测模型要学习这些语境的影响，就需要几个不同的特征编码器或嵌入层，这些添加物可能会大大增加预测模型的复杂性，使模型更难训练
- 通过语言生成管道进行预测的方法是一个序列到序列的结构。通过流动性描述，流动性数据和其他支持性的上下文信息都被转化为自然语言句子。然后，在移动性翻译步骤中，这些描述性的句子被作为输入，而表示预测的自然语言句子被生成为输出。

- 提出了一种新颖的双分支架构 SHIFT, 用于通过语言生成管道进行上述人类移动预测下的核心移动翻译部分
- 该架构由一个主要的自然语言分支 (NL) 和一个辅助移动性分支 (Mob) 组成
- NL 分支被实现为序列到序列的结构来“翻译”移动性描述, 而 Mob 分支专注于学习移动性模式。辅助分支的目的是进一步提高主分支生成移动性预测的能力。
- 本文的贡献:
 - 通过语言生成管道探索并开发了一种新型的流动性预测方法
 - 提出了一个双分支网络, SHIFT, 它有一个用于语言生成的主分支和一个用于明确学习移动模式的辅助分支。介绍了一种基于动量平均的方法来连接这两个分支
- 未来的工作: 开发一种移动性自动生成语言的方法, 其目的是为基于语言生成的移动性预测提供多样化提示

3. Modeling Spatio-temporal Neighbourhood for Personalized Point-of-interest Recommendation

(1) 研究内容: 将用户和地点一起建模, 从而捕捉用户对地点的个人和动态偏好, 同时关注用户对位置的距离/时间的接受程度

(2) 创新点及要点:

- 将带有时间信息的知识图谱 (称为 TKG) 引入到 POI 推荐中, 包括带有时间戳的用户和地点
 - 克服现有的基于序列和基于 KG 的推荐方法的局限性
- 在 TKG 的基础上, 提出了一个空间-时间图卷积注意力网络 (STGCAN), 一个通过动态捕捉空间-时间邻域来学习用户对 TKG 的偏好的新型网络
- 在 STGCAN 中, 在 TKG 上构建接受场, 在每个时间戳上分别聚合用户和位置的邻域。而将空间-时间间隔作为用户对距离/时间的接受度来衡量, 并进行 self-attention
 - 考虑了用户对位置的个人偏好, 并开发了关注机制来衡量每个用户对距离和时间的接受程度
- 本文中考虑的 POI 推荐的影响因素:
 - 个人偏好: 个人对同一地点的不同偏好
 - 动态偏好: 用户对同一场所不同时间的偏好发生的变化
 - 个人对距离/时间的接受程度: 对于相同距离/时间的场所, 不同的人可能对其有不同的接受程度
- 本文的贡献:
 - 提出了一个空间-时间图卷积注意力网络, 这个网络可以在 TKG 上学习用户/位置之间的动态关联性, 以模拟用户的 POI 兴趣。作者认为 STGCAN 是第一个探索 TKGs 来学习用户在 POI 推荐中的个人偏好的模型

- 在 STGCAN 中，考虑了用户对位置的个人偏好，并在 TKG 上分别构建了用户/位置感知域，以捕捉用户/位置的邻域来学习表征
- 在 STGCAN 中，开发了一种注意力机制，可以衡量每个用户对距离和时间的接受程度，从而增强 POI 推荐

4.A Systematic Analysis on the Impact of Contextual Information on Point-of-Interest Recommendation

(1) 研究内容：考虑不同影响因素（位置属性、用户属性，以及其他信息）这些主要的上下文信息组合对 next-POI 推荐的影响

(2) 创新点及要点：

- 提出了不同的上下文模型，并分析了 POI 推荐中不同主要上下文信息的融合，主要贡献：
 - 提供了对上下文感知位置推荐的广泛调查
 - 量化和分析 POI 推荐中的不同上下文信息对可用基线和两个新的线性和非线性模型的影响，这些模型可以将所有主要的上下文信息整合到单一推荐模型
- POI 推荐存在的两个问题，即数据稀疏性和冷启动
 - 数据稀疏性是指给定大量的 POI，而用户只能访问其中的几个，user-POI 交互矩阵变得非常稀疏。使得对用户和 POI 之间的协作交互进行建模变得非常困难
 - * 解决数据稀疏问题，最近多使用上下文感知推荐系统 (CARS)，CARS 在考虑用户当前上下文的情况下为用户提供建议。
 - * 用户的上下文可以定义为一组影响用户对特定项目的感知和接受的因素和限制
 - 冷启动问题是指向那些交互记录非常有限或没有交互记录的用户推荐 POI，交互记录非常有限或没有交互记录的 POI 被视为冷项目，模型通常无法有效地推荐这些项目
- 本文主要研究的问题：
 - 不同模型如何有效地将多个上下文因素纳入推荐？
 - 不同的评估指标如何捕捉上下文信息对各种模型的影响？
 - 如何在线性和非线性模型中加入不同的上下文因素？
 - 包含上下文信息的模型如何为具有不同行为的用户执行？
- 本文的大致流程：
 - 考虑了几个先前提出的 baseline 模型，以证明缺乏对上下文模型的深入考虑
 - 定义了可以在 POI 推荐系统中使用的不同上下文模型，并将它们融合到 MF 和 NN 推荐方法中
 - 通过结合不同的上下文信息来分析主要影响上下文对 POI 推荐的影响，以创建融合模型
 - 其目标不是证明任何上下文信息对任何模型的影响。相反，其目标是描述上下文对这两个特定模型的影响并提供结构化审查

- 目标是确定表现最佳的上下文因素的选择以及考虑多种因素组合的影响
- 未来的工作：
 - 提出不同的评估指标来测试上下文感知推荐系统中上下文信息的质量
 - 将研究扩展到具有某些特征的各种数据集，并对不同数据集特征对性能的影响进行彻底调查

5. Graph-Enhanced Spatial-Temporal Network for Next POI Recommendation

(1) 研究内容：捕捉 POI 网络之间的高阶复杂地理影响（而不仅仅是简单的考虑距离因素）

(2) 创新点及要点：

- 提出了一种新颖的基于图的空间依赖建模 (GSD) 模块，该模块专注于通过利用图嵌入来显式地建模复杂的地理影响
 - GSD 从设计的 POI 语义图中捕获两种类型的地理影响，即基于距离和基于转移的影响
- 提出了一种新颖的图增强时空网络 (GSTN)，结合了用户空间和时间依赖性，用于下一个 POI 推荐
 - GSTN 由用于用户特定时间依赖建模的长短期记忆 (LSTM) 网络和用于用户空间依赖学习的 GSD 组成
- 本文的模型旨在明确捕捉 POI 中不同的高阶地理影响：
 - 开发了一个基于图嵌入的基于图的空间依赖 (GSD) 建模模块。反映 POI 之间成对关系的 POI 语义图被构建为 GSD 的输入，使 GSD 能够基于连续和非连续访问的 POI 学习各种地理潜在表示
 - 构建的 POI 语义图来自全局视图（即包含数据集中的所有 POI），这阻止了 GSD 模块仅捕获连续签到之间的浅层影响（即分别捕获基于距离和基于转移的地理潜在表示来模拟相应的地理影响）
 - 将 GSD 学习的地理表征作为空间依赖与基于 LSTM 的方法学习的时间依赖融合在一起，从而提出了一种新的 Graph-enhanced Spatial-Temporal Network (GSTN) 用于下一个 POI 推荐（即 GSTN 利用名为 Time-LSTM 的 LSTM 变体来捕获用户特定的时间依赖关系，然后融合空间和时间依赖关系来推荐用户在下一个时间戳中最有可能访问的 POI）
- 本文的主要贡献：
 - 对高度复杂的地理影响进行显式建模，以便在下一个 POI 推荐中充分利用空间依赖性
 - * 设计了一种基于图嵌入的新型 GSD 模块，以捕获 POI 之间的高阶复杂地理影响。设计了两个 POI 语义图来学习每个 POI 的基于距离和基于转移的地理潜在表示
 - 为下一个 POI 推荐提出了一种新颖的 GSTN 模型

* GSTN 专注于整合 POI 的空间依赖和用户的时间依赖从而估计用户偏好。一种新颖的时空注意力聚合模块旨在有效地整合空间和时间依赖性

- 未来的工作：进一步探索除时空依赖性之外的其他上下文信息，即 POI 类别和社交网络，以提高下一个 POI 推荐的性能

6.Spatial-Temporal Interval Aware Sequential POI Recommendation

(1) 研究内容：改进目前的自注意力网络 (SAN), 以降低模型的参数规模或计算负担

(2) 创新点及要点：

- 利用两种轻量级方法，时间感知位置编码器 (TAPE) 和间隔感知注意块 (IAAB)，通过分别考虑 POI 之间的时空间隔来推动 SAN，不需要额外的参数也不需要高计算成本
 - TAPE 根据时间戳动态调整序列中的位置，并通过正弦变换生成位置表示，可以增强序列表示以反映所有 POI 之间的绝对顺序和相对时间接近度
 - IAAB 将缩放的时空间隔逐点添加到注意力图中，可以促进注意力机制在时间条件的约束下重视所有 POI 之间的空间关系，并提供更可解释的推荐
 - 将这两个模块集成到 SAN 中，并提出了一个 Spatial-Temporal Interval-Aware 顺序 POI 推荐器，即 STiSAN，作为端到端部署
- 空间和时间信息是顺序 POI 推荐中的两个关键和互补因素
 - 空间信息可以描述两个 POI 之间的物理接近度，尤其是当个体移动历史通常表现出空间聚集现象时
 - 时间信息可以反映 POI 之间的相对时间接近度，对时间因素进行建模将有利于区分这些相同的序列并实现更细粒度的序列表示
- 本文的贡献：
 - 利用两种轻量级方法时间感知位置编码器 (TAPE) 和间隔感知注意块 (IAAB) 来分别考虑 POI 之间的相对时空接近度，其中既不需要额外的参数也不需要显着的计算负担。
 - * 将时间戳编码为序列表示的 TAPE 可以反映相对时间接近度
 - * IAAB 明确地将时空关系引入注意力图中，促使人们关注空间相关性
 - 将 TAPE、IAAB 集成到 SAN 中，并提出时空区间感知顺序 POI 推荐框架 (STiSAN)，作为端到端部署，以实现更细粒度的偏好建模并提供更可解释的推荐。
- 实验所探究的问题：
 - STiSAN 能否提供与几个最先进的 baseline 相比更出色的性能？
 - 在本文的框架下，两个提议的组件 TAPE 和 IAAB 的有效性如何？
 - TAPE 和 IAAB 能否有效地应用于 vanilla self-attention 网络？
 - STiSAN 对不同稀疏度级别的敏感度如何？
- 未来的工作：将细致地探索自注意力学习并包含在时空关系矩阵中的顺序依赖关系之间的联系和差异

7. Time-sensitive POI Recommendation by Tensor Completion with Side Information

(1) 研究内容：使用张量完成模型范式，以实现更有效的时间感知 POI 推荐

(2) 创新点及要点：

- 张量完成最近在时间感知推荐系统中获得了一些关注。该问题利用观察到的条目将用户项目时间张量分解为用户、项目和时间的低等级嵌入矩阵，这样就可以跟踪底层的低等级子空间结构，以填补时间感知推荐的缺失条目
 - 这些张量完成方法忽略了 LBSNs 中可用的社会空间背景信息，这对 POI 推荐非常重要，因为人们倾向于与他们的朋友分享他们的偏好，而近处的事物比远处的事物更有关联。
- 本文利用社交网络和 POI 位置的侧面信息来增强张量完成模型范式，以实现更有效的时间感知的 POI 推荐
 - 提出了一个基于新型社会 Hausdorff 距离函数的正则化损失头，以优化重建的张量
 - 用位置熵来量化不同 POI 的受欢迎程度，以防止非常受欢迎的 POI 被过度代表，从而压制其他更多样化的 POI 的出现
 - 为了解决负面采样的敏感性，通过将观察到的张量中所有未标记的条目视为负面来训练整个数据的模型，并以一种聪明的方式重写损失函数来减少计算成本
- 本文中有一个结论：如果两个用户是朋友，他们倾向于在相同或附近的地方检查
- 在本文中，旨在利用 LBSN 中的社会空间信息作为侧面信息来改善基于神经张量完成的 POI 推荐。
 - 采用光谱法来获得初始用户、POI 和时间嵌入的粗略估计，以进行嵌入初始化
 - 用包括所有未标记数据在内的整个数据来训练我们的神经张量模型，以消除负采样的缺点
 - 为了解决在所有张量项上直接计算最小二乘损失的高计算成本，以一种聪明的方式重写这个损失函数，使计算和学习更有效率
- social Hausdorff 距离函数的反向传播公式
 - Hausdorff 距离度量测量两组点之间的距离。在模型设计中，希望最小化每对朋友的两组签到位置之间的 Hausdorff 距离，以执行社会同质性理论，但存在一些问题：
 - * 原始 Hausdorff 距离度量的输入是位置，而不是本文中的神经张量模型的输出（即每个用户-POI-时间交互的概率）
 - * ，即使修改本文的 social Hausdorff 距离函数以允许用户-POI-时间交互概率，原始 Hausdorff 距离函数中的最小化算子 $\min(\cdot)$ 就其输入而言并不是一个平滑函数，因此它不支持反向传播
 - 需要修改这个算子来支持反向传播学习。提出的社会 Hausdorff 距离函数使模型能够整合社会关系和 POI 位置，以规范张量完成公式。
 - 为了提高推荐的多样性，利用位置熵来推荐那些访问频率较低的 POI，考虑到它们通常比每个人都访问的地方更能揭示真实的用户社交力量。

- 本文的贡献：
 - 提出了基于社交 Hausdorff 距离的损失函数的可反向传播公式，它使模型能够利用社交图和 POI 位置来规范张量补全公式
 - 将社交空间损失头与位置熵 POI 权重相结合，以提高推荐的多样性
 - 用包括所有未标记数据的整个数据来训练模型，以克服张量补全中负采样的缺点，并巧妙地重写最小二乘损失以降低时间复杂度
 - 使用频谱方法仔细初始化潜在用户/POI/时间嵌入，以避免在训练期间被困在静止点
- 模型框架：
 - 通过谱初始化方法将每个用户、POI 和时间间隔与嵌入相关联
 - 每个条目的值通过神经网络从相应的嵌入中学习
- 模型的新颖处：
 - 使用具有两个头的混合损失函数
 - * 加权 Hausdorff 距离头来利用社会空间信息
 - * 原始张量与重构张量在整个数据上的均方误差
 - 使用联合训练的策略来优化重建的张量
- 实验所回答的问题：
 - 是否有必要将时间维度纳入推荐而不是考虑只是一个 user-POI 交互矩阵？
 - TCSS 能否在时间感知推荐方面优于现有最先进的张量补全模型？
 - 时间维度上的时间粒度如何影响推荐的性能？
 - 不同类别兴趣点的表现是否一致？
 - 消融研究：TCSS 的训练性能与使用负采样和其他初始化方法的同类产品相比如何？
 - 模型超参数如何影响结果质量？

8. Leveraging social influence based on users activity centers for point-of-interest recommendation

(1) 研究内容：通过将社会、地理和时间信息整合到矩阵分解 (MF)，从而推荐 next-POI

(2) 创新点及要点：

- 基于两个因素对社会影响进行建模：
 - 用户之间在常见签到方面的相似性
 - 用户之间的友谊
 - 基于明确的友谊网络 and 用户之间的高签到重叠引入了两个级别的友谊。本文的友谊算法基于用户的地理活动中心
- 在 LBSN 上定义了两种类型的友谊
 - 明确的朋友是那些在 LBSN 中相互关注的用户

- 隐含的朋友是那些具有大量常见签到的用户，通常具有非常相似的品味，由于这些行为相似性而产生了一些友谊
- 提出了一个社交用户活动中心 POI 推荐系统，称为 SUCP, 与以前的工作相比
 - 通过考虑用户在其活动中心的社交关系来提高推荐系统的性能
 - 基于 MF 以及在时间和地点的影响下创建的用户的社交信息和活动中心的组合来预测用户偏好
 - 为了证明我们提出的社交方法的有效性，我们从 SUCP 广告中删除了社交信息，研究其对性能的影响
- 本文提出了一种新方法，该方法基于三个上下文因素检查用户的偏好：地理、社会和时间信息，本文的贡献：
 - 所提出的模型从多个角度检查用户对 POI 的兴趣，新颖之处在于联合建模用户的活动中心和他们的社会关系
 - 考虑两种类型的社会影响，包括用户之间的友谊和访问过的兴趣点的相似性。实现了用户和他们的朋友之间的相似性权重。通过这种方式，推荐系统识别出用户与其朋友之间的行为相似性。
- 主要思想是将用户的时空活动中心以及他们的朋友纳入推荐过程。
 - 增加了用户对 POI 推荐系统的了解，并使其能够从社会角度对他们的行为进行建模
 - 用户的活动中心反映了个性化的兴趣，而社交信息则考虑了来自朋友的兴趣，无论是显性朋友，还是隐性朋友，都会对用户的签到行为产生影响。
- 未来的工作：
 - 可以将其他上下文信息合并到建议的模型中，例如用户的评论或评论、分类信息
 - 可以通过其他友谊和相似性指标（例如经常访问的签到时间）对社会影响进行建模

9. Combining Non-sampling and Self-attention for Sequential Recommendation

- (1) 研究内容：现有的顺序推荐方法在成对学习普遍采用负采样机制（例如随机和均匀采样），给模型带来了训练不足的缺陷，降低了整个模型的评估性能
- (2) 创新点及要点：
 - 提出了一种结合了非采样机制和自注意机制的非采样自注意顺序推荐（NSSR）模型
 - NSSR 模型在保证模型高效训练的前提下，将训练集中的所有 pairs 作为训练样本，以达到对模型进行充分训练的目的
 - 将交互序列作为当前用户表示，并提出一种新的损失函数来实现非采样训练机制
 - 基于 self-attention 机制，将交互序列作为当前用户表示，利用整个数据构建训练对，对模型进行全面训练，从而提高模型的推荐性能
 - 提出了一种新的损失函数来降低模型的时间复杂度，并且与传统的非采样训练方法相比，保证了我们的 NSSR 模型的训练效率

- 负采样机制相关：
 - 模型训练方法都是基于负采样机制，即从所有非正样本中随机抽取一些负样本，然后与正样本建立训练对，实现成对学习。
 - 负采样机制的优点是模型训练速度快，效果好。但随机负采样无法考虑数据集中的所有负样本，因此不利于模型的充分训练
 - 如果模型将所有非正样本都作为负样本进行采样，则会带来耗时且低效的模型训练
- 本文的主要贡献总结如下：
 - 首次提出了一种结合了非采样和 self-attention 机制的顺序推荐方法 NSSR 模型。NSSR 模型在训练过程中使用了数据集的所有训练样本，从而达到充分训练的目的
 - 在 NSSR 模型中提出了一种新的非采样损失函数，解决了传统非采样训练方法造成的时间复杂度高的问题，提高了模型训练的效率
- 对顺序推荐提出了两点建议：
 - 针对顺序推荐中负向抽样机制的局限性，首次提出了非抽样训练的改进方法，并将在困难样本挖掘方面做进一步探索
 - 对于顺序推荐，用户在项目上的停留时间非常重要。虽然研究人员最近提出了一些利用时间信息的改进方法，但很少有考虑细粒度时间信息的工作，如季节和假期。

10. Research on Personalized Minority Tourist Route Recommendation Algorithm Based on Deep Learning

(1) 研究内容：

- 利用对少数民族旅游需求群体兴趣点的个性化挖掘，提取社交网络中的客户数据特征，构建有趣的话题因素、地理位置因素、用户访问频率因素等数据特征
- 利用 LDA 话题模型和矩阵分解模型对用户签到记录进行特征向量处理，建立深度学习推荐模型（DLM）
- 利用该模型与传统的推荐模型和单一数据特征模块的推荐模型进行比较

(2) 创新点及要点：

- 提出了一个深度神经网络推荐框架，将 DNN 网络与 LDA 主题模型和矩阵因子化算法相结合，并利用词嵌入技术将社交网络中的用户偏好特征、地理因素特征和概率主题特征被整合到少数民族旅游线路推荐任务中，通过神经网络学习特征间的高层互动，然后向用户做出个性化推荐
- 实验结果表明：在少数民族旅游线路个性化推荐系统中，用户记录的地理因素特征对推荐效果的影响远大于用户访问的主题和频率

11. Context-aware POI Recommendation using Neutrosophic Set for Mobile Edge Computing

- (1) 研究内容：传统的 POI 推荐方法容易受到数据稀疏性的影响，对 POI 排序结果缺乏清晰有效的解释。用户所做的 POI 选择受各种上下文属性的影响

(2) 创新点及要点:

- 将 POI 推荐转换为基于中智集 (NS) 的上下文多属性决策问题, 适用于表示模糊决策信息
 - 建立了一个统一的上下文信息框架
 - 提出了 POI 的上下文多属性 NS 转换模型, 包括单维属性的 NS 模型和多维属性的 NS 模型
 - 通过多属性 NS 的聚合, 推荐最符合用户偏好的 POI
- 上下文感知 POI 推荐存在很多困难, 主要体现:
 - 由于各种 POI 上下文数据的异构性, 很难设计一个统一的框架来整合多个上下文属性
 - 用户的签到行为是一个复杂的决策过程。有必要对上下文信息对用户决策的影响进行合理的建模
 - 当前的 POI 推荐研究大多不够全面, 无法考虑影响用户选择的属性, 无法有效整合它们
- 提出了一种基于边缘计算中智集的上下文感知 POI 推荐方法:
 - 将 POI 推荐问题转化为多标准决策 (MCDM), 中智集 (NS) [7] 是模糊集的扩展。它使用真隶属度、不确定隶属度和假隶属度来表示模糊决策信息, 可以细致准确地描述客观事物的模糊性质, 适用于解决 MCDM 问题。
 - 本文的 POI 推荐方法属于基于内容的解决方案, 是缓解数据稀疏问题的重要手段
 - 本文基于中智集的方法可以清晰地得到一个兴趣点各属性的隶属度、非隶属度和不确定性, 可以有效地解释兴趣点的排序结果
- 本文的贡献包括理论分析和实验结果:
 - 提供了一个新颖的统一框架来表示和充分挖掘用户签到上下文信息, 其中上下文属性由单维属性 NS 模型或多维属性 NS 模型
 - 设计了一个客观的机制来衡量用户的个人属性偏好程度, 并使用 NS 的聚合算子来生成最终的推荐列表
- 鉴于签到数据所反映的用户偏好的模糊性和不确定性, 本文从用户决策的角度将 POI 推荐转化为多属性决策问题, 并提出了一种基于中子集的上下文感知的 POI 推荐方法
 - 将地理位置、兴趣主题、受欢迎程度和社会关系四个属性有效地结合起来, 将影响 POI 选择的各种属性转换为基于中性集的相同表示, 提供了一个研究 POI 推荐问题的有效模型
 - 基于相似度构建地理位置和兴趣主题的单维属性 SVN 转化模型, 基于情感分析构建人气和社会关系的多维属性 SVN 转化模型, 从而为用户的各属性偏好提供有效的量化建模方法
 - 通过每个属性的中智集可以清楚地得到每个 POI 属性的真隶属度、不确定隶属度和假隶属度, 提高了推荐结果的可解释性, 使作者能够从用户决策的角度研究和分析候选 POI

- 利用中智集综合算子综合计算多属性中智集，目标权重计算给出每个属性的方法，综合考虑生成最终的推荐列表
- 该方法可以有效地扩展，不仅可以应用于以上四个属性的综合，还可以推广到各种属性的集成

12. Online POI Recommendation: Learning Dynamic Geo-Human Interactions in Streams

(1) 研究内容：在流中为在线 POI 推荐的动态地理-人类互动建模问题

- 在访问过程中，用户和地理空间环境（如 POI、POI 类别、功能区等）之间存在着动态和相互的互动

(2) 创新点及要点：

- 将流中的地缘人际互动建模问题制定为一个新的深度交互式强化学习框架
 - 一个代理是一个推荐者，一个行动是要访问的下一个 POI
 - 将强化学习环境独特地建模为用户和地理空间背景（POI、POI 类别、功能区）的联合和连接的构成
 - 一个用户访问流中的 POI 事件更新了用户和地理空间环境的状态；代理感知到更新的环境状态来进行在线推荐
 - 在初步工作中，通过单独嵌入用户和地理空间背景的静态知识图来建立一个单用户访问流的模型，然后将这两个表征串联起来以预测推荐
 - * 只专注于对单一用户的 POI 访问流进行建模，而不是混合用户的 POI 访问流，以简化在线推荐。
 - * 特别是，表示模块分别学习了用户和地理空间环境的表示。
 - * 然后，将用户和地理空间环境的表征串联起来作为环境状态。
 - * 模仿模块将环境状态作为输入，利用其策略网络向用户进行个性化的下一个 POI 推荐
 - 在扩展的工作中，通过将所有的用户、访问和地理空间背景统一为一个动态的知识图流来对混合用户的事件流进行建模，以便对人与人、地理与人、地理与地理的互动进行建模
 - 设计了一种退出机制来解决过期信息的挑战，设计了一种元路径方法（克服稀疏性）来解决推荐候选者生成的挑战，并开发了一种新的深度策略网络结构来解决行动空间变化的挑战
 - 提出了一种有效的对抗性训练方法进行优化
- 将流中的人地互动建模问题制定为一个强化学习任务。
 - 基本思想是将强化学习代理视为一个推荐者，并将强化学习环境视为用户和地理空间环境（如 POI、POI 类别和功能区）的联合组成
 - 因此可以利用强化学习中的代理-环境互动来模拟用户和地理空间环境之间的互动
- 本文的学习框架包括两个主要模块：

- 表示模块: 表示模块是为了学习和跟踪用户和地理空间环境的状态表示
- 模仿模块: 模仿模块是利用用户和地理空间环境的表征作为状态, 将推荐的 POI 作为行动, 以模仿用户的访问行为
- 用户访问模式的模仿准确性被反馈出来, 以指导表示和模仿模块的参数优化。当模仿模块完美地模仿用户访问模式时, 表示模块会产生最准确的互动用户和地理空间环境的嵌入
- 经过训练的模仿模块将选择具有最高 Q 值的 user-POI 对, 并在飞行中进行更新的推荐
- 本文的贡献:
 - 为在线 POI 推荐制定了数据流中地理-人类互动的模型问题。提出了一个新的视角, 通过统一流中推荐和动态地理-人类互动建模来攻击在线 POI 推荐
 - * 人类的访问活动是一个用户和地理空间实体之间的相互影响的过程
 - 提出了一个基于表征-模仿的深度交互式强化学习框架。为了解决流中动态交互建模问题, 我们提出了一个新颖的深度交互强化学习框架。
 - * 这个框架包括一个表示模块和一个模仿模块, 这两个模块构成了一个闭环的互动学习系统
 - * 前者是进行动态知识图谱学习, 学习用户和地理空间实体的状态表示
 - * 后者是通过策略网络进行在线下一个 POI 推荐
 - 开发技术解决方案, 解决混合用户数据流中的多层次互动动态。
 - * 混合用户数据流中的互动有三个层面的动态, 包括连接动态、拓扑动态和语义动态, 都会带来挑战
 - * 为了应对这些挑战, 提出了有效的技术解决方案
 - 提出了一种退出机制, 在合理的规模上保持动态的 KG, 并降低计算的复杂性
 - 开发了一种基于元路径的候选者生成方法, 以克服稀疏 KG 带来的挑战
 - 设计了一个新的策略网络, 生成 Q 值来选择推荐的用户-POI 对, 以解决动态行动空间的挑战
 - 实验来回答以下问题:
 - * 提出的推荐框架是否优于现有方法?
 - * 提出的框架的稳健性如何?
 - * 框架的每个部分对于提高推荐性能是必要的吗?
 - * 奖励函数对 POI 推荐性能有何贡献?
 - 结论:
 - * 提出了一种新颖的 POI 推荐框架, 将动态 KG 与强化学习设置相结合
 - * 由于基于 KG 的推荐中的常见做法无法捕捉到人类移动性的多层次动态, 引入动态 KG 作为环境。具体来说, 将动态 KG 的表示视为强化学习中的状态
 - * 为了解决不可控的图尺度问题, 开发了一种退出机制来删除过时的信息。为了减少行动空间, 设计了一种基于元路径的 POI 候选生成方法来选择最可能的 POI 进行推荐

- * 为了解决动态行动空间的问题，提出了一个新的策略网络，以状态动作对作为输入，并为每一对输出 Q 值。选择具有最高 Q 值的对作为推荐

13.FedPOIRec: Privacy Preserving Federated POI Recommendation with Social Influence

(1) 研究内容：保护隐私的位置预测以帮助用户发现新的兴趣点 (POI)

(2) 创新点及要点：

- 提出了 FedPOIRec，这是一种保护隐私的联合学习方法，用来自用户社交圈的特征来加强顶级的 POI 推荐。
 - FedPOIRec 框架建立在本地数据从未离开所有者的设备的原则之上，而本地的更新是由参数服务器盲目地汇总的
 - 本地推荐者通过允许用户交换他们所学到的参数而得到个性化，实现朋友之间的知识转移
 - 提出了一个保护隐私的协议，通过利用 CKKS 全同态加密方案的特性，在联合计算后整合用户朋友的偏好
- 与用户数据有关的隐私问题可以通过利用联合学习的方法来最小化。在这种情况下，模型更新的随机梯度下降 (SGD) 迭代是在本地进行的，在数据所有者的设备中。来自每个参与的客户端的更新被分发到一个参数服务器，该服务器执行一个聚合步骤以形成新的全局参数，该过程持续到模型收敛为止。
- 利用一种 SMC 方法，允许参数服务器只学习聚合的结果。将联合学习与安全的聚合方案相结合，可以形成一个保护隐私的推荐框架。尽管潜伏因子模型可以带来高的推荐质量，但其准确性会受到社会特征的进一步影响。例如，用户的朋友的偏好可以带来更好的推荐。也就是说，同源性表明具有共同兴趣的个体倾向于分享友谊关系。
 - 在联合学习中，朋友关系是不能直接使用的，因为本地数据永远不会被传输到外部实体。
 - 一个直接的方法是加强个性化，并因此提高推荐质量，在用户之间进行知识转移，即通过潜在因素模型学习的本地向量。例如，矩阵分解捕捉用户向量和相应的互动项目向量之间的偏好，以努力为未观察到的行动提供一个估计。在这项工作中，利用联合计算后社交圈中学习到的向量的相似性，从直接邻居那里获益。具体来说，在第一邻域内传输用户的向量是为了创建一个加权平均向量，以捕捉来自朋友的偏好，从而提供更高质量的推荐。
 - 然而，以普通格式传输这些参数会导致重建一个特定用户的偏好。一个被动的用户可以从他们的社交圈中收集基础用户向量，以确定个人对特定项目 (POI) 的偏好。为了克服这一挑战，提出了一种基于完全同态加密 (FHE) 方案的隐私保护方法，它允许通过保留数据的机密性来计算加权平均向量。本文的方法是通用的，也可以应用于不同的任务，当计算需要隐私问题最小化时。
- 本文的主要贡献：

- 提出了 FedPOIRec, 这是一个保护隐私的联合学习框架, 可以与任何协作过滤算法整合, 以提供 top-N POI 推荐
- 提出了一种有效的保护隐私的方法, 用于基于 FHE 计算的数据聚合。从社会关系中获益, 并在加密数据上汇总个人层面的参数, 以提高个性化和推荐质量, 同时尽量减少数据暴露
- 在联盟环境中调整了两个推荐模型: 一个是用贝叶斯个性化排名 (BPR) [11] 优化的传统矩阵分解模型, 一个是基于卷积神经网络的顺序推荐器 (CASER)。据我们所知, 这是在联合学习中首次尝试基于顺序模式的推荐
- 提出了一个通用的隐私保护学习程序, 可以与任何基于模型的协同过滤算法相结合。在 FedPOIRec 中,
 - 用户不外包他们的任何本地观察 (即对 POI 的访问), 并整合了一个安全的聚合策略, 以尽量减少对参数服务器的本地更新暴露。
 - 此外, 考虑了一个标准的联合学习场景, 不要求所有的用户在任何特定的时间都是可用的。
 - 最后, 探讨了联合学习程序后推理阶段的社会影响。在现实世界的情况下, 联合过程发生在只有一部分用户可用的时候。因此, 在训练阶段制定具有隐私保证的参数传输会产生沉重的通信和计算开销。
 - 为了避免客户端的巨大成本, 在全局模型生成后, 使用 FHE 结构在朋友之间融合所学参数。本文的隐私保护协议允许计算加权平均向量而不暴露局部参数, 也可以适用于推荐系统以外的任务。
- 未来的研究方向: 联合学习和基于隐私保护
 - 对于联合设置, 应该研究关于个性化的进一步分析和复杂的算法, 应该对能够导致产生更多通用和高质量模型的优化算法进行评估, 并且应该提出在训练阶段将社会特征与通信效率整合的方法
 - 在隐私方面, 对现有的安全聚合方案所提供的安全和隐私保障进行正式的安全分析是至关重要的, 应该评估所提出的隐私保护协议在其他学习任务 (如聚类) 中的加权平均向量计算的适应性, 以及评估探索使用完全同态方案进一步减少计算和通信开销的方法

。

14. Point-of-Interest Recommender Systems based on Location-Based Social Networks: A Survey from an Experimental Perspective

(1) 研究内容: 对过去 10 年中有关 POI 推荐的研究进行了系统回顾

(2) 创新点及要点:

- 该综述所探究的问题:
 - 基于 LBSNs 的 POI 推荐的最新进展是什么?

- 哪些是最相关的工作？作者想更详细地分析那些在社会上有更大影响力的作品，并提取可能的原因，暴露这些特点，以便未来的研究人员在研究中关注它们。
- 如何评估这些推荐器？使用了哪些协议/指标/数据集？作为本综述的一个具体目标，作者想深入了解 POI 推荐文献中所遵循的具体评估方法，因为这是一个潜在的错误行为的来源，可能会限制该领域的整体改进。
- 未来需要解决的最重要问题是什么？基于对其他研究问题的回答，总结并提出了在使用 LBSNs 的数据时，处理 POI 推荐问题的研究人员应该考虑的最重要的议题。
- 本文的主要贡献：
 - 对 2011 年至 2020 年期间基于 LBSNs 的最先进的 POI 推荐模型进行了全面回顾
 - 对这些工作中所使用的算法方法进行分类，以及这些模型所处理的上下文信息，和用于评估其性能的评估方法
 - 列出该领域的挑战和开放性问题，以及潜在的未来方向
- 基于内容的过滤 (CB)
 - 基于内容的推荐系统分析项目和/或用户特征（内容），并使用它们创建用户和项目配置文件，以向目标用户推荐与她以前喜欢的项目相似的项目
 - 这种类型的系统使用三个主要组件：
 - * 内容分析器，它预处理项目的可用信息以提取关键字、概念或其他信息
 - * 轮廓学习器，使用项目的内容信息，为系统中的每个用户构建一个配置文件
 - * 将用户配置文件与系统中的项目进行匹配的过滤组件
- 协同过滤
 - 协同过滤 (CF) 技术分析用户和项目之间的交互，以便在提出建议时建立它们之间的模式
 - 这些技术通常分为两组：
 - * 基于内存的，通过计算用户和/或项目 [91] 之间的相似性直接使用交互（通常表示为用户项目矩阵）执行推荐
 - 通过利用系统中其余用户/项目之间的相似性向目标用户推荐最合适的项目
 - * 以及基于模型的算法，建立一个通过近似存储在偏好或交互矩阵中的信息的预测模型
 - 通过将用户和项目都转换为低维潜在因子空间来近似用户-项目矩阵，以便可以通过在该空间中应用点积来解释（或恢复）用户-项目交互
- 混合推荐器
 - 单独地，每个推荐算法在某些情况下可能有一些缺点。出于这个原因，通常组合几个模型来缓解这些问题。
- POI 推荐系统的六大类算法
 - 基于相似性: 对应于经典 k-NN 方法，其中使用用户或项目之间的相似性
 - 因式分解: 该算法是对矩阵进行分解

- 概率方法: 通常会考虑几个随机变量, 这些随机变量根据某些规律或公式可能相关, 在推荐中通常涉及用户、项目以及前者 and 后者之间的潜在交互
- 深度学习方法: 利用人工神经元层, 通过优化可微函数来获得数据的不同表示
- 图表/链接方法: 基于链接或基于图的技术使用存储在系统中的数据构建一个或多个图
- 混合方法
- 目前研究存在的问题以及可能的在未来 POI 推荐系统研究方向:
 - 目前的研究:
 - * 问题: 尽管已经对 POI 推荐问题进行了多项研究, 但仍有可能在该领域找到未解决的问题
 - 关于算法, 矩阵分解以及最近的深度学习是使用来自 LBSN 的数据时在 POI 推荐中非常流行的方法; 但是, 通常很难解释为什么会提出这些方法的建议, 因为它们的行为就像一个黑匣子
 - 关于评估方法, 认为不同算法之间的比较必须始终尽可能透明和公平, 以确定哪些提议优于其他提议
 - 关于数据集
 - * 解决方法:
 - 详细解释如何评估算法, 说明使用的指标、拆分类型以及用作基线的其余模型
 - 清楚地标明所用数据集的统计数据, 说明是否已执行任何预处理步骤, 并显示所用数据的最终详细信息, 包括用户数、兴趣点和签到数
 - 为代码提供详细描述, 以实现论文中提到的相同结果
 - 未来的研究:
 - * 走向现实的方法论:
 - 研究人员应该形式化并批判性地思考他们想要解决的任务以及评估方法是否与任务匹配, 或者他们是否通过设计使其变得简单或过于困难
 - * 考虑用户类型或角色: 正如最近的研究表明, 登记数据可用于描述至少四种类型的旅行者: 度假者、探险者、航海者和环球旅行者, 从而超越了通常考虑的经典旅游角色 (休闲或商务)
 - * 对抗性分析和数据质量: 讨论 POI 推荐中使用的的数据质量
 - * 新颖的信息来源、偏好和隐私: POI 推荐问题通常会考虑多个信息源, 但未来会有更多信息源可用,
 - 缺乏处理场地时间表的工作
 - 在在更全球范围内解决问题的通用架构或框架, 甚至在有或没有传感器的情况下与 POI 交互是, 尽管其明显的兴趣和吸引用户的潜力, 但目前尚未进行调查
 - 在 POI 推荐的同时考虑对用户隐私的保护

- 反事实和翻译到现实世界: 实验工作中使用的大多数数据集来自数量有限的 LBSN, 这可能表明对这些系统的要求和需求存在偏见
- 添加约束: 基于约束的推荐系统是一系列推荐方法, POI 推荐时用户通常会面临一些限制或约束: 期望的景点价格、必看场所、最长行程长度等, 允许 POI 推荐算法结合约束并根据这些变化的条件调整他们的建议
- 可扩展性和效率: 考虑到除了用户-项目交互矩阵之外的其他信息维度, 需要内存资源, 还需要复杂的算法, 这些算法难以扩展和高效执行

15. Curriculum Meta-Learning for Next POI Recommendation

(1) 研究内容: 探索了城市转移的下一个 POI 来搜索推荐, 将知识从具有丰富数据的多个城市转移到具有稀缺数据的冷启动城市

(2) 创新点及要点:

- 提出了一种新颖的课程硬度感知元学习 (CHAML) 框架
 - 将硬样本挖掘和课程学习结合到元学习范式中
 - CHAML 框架同时考虑了城市级和用户级的难度, 以增强元训练期间的条件抽样
 - 为城市抽样池使用易到难的课程, 以帮助元学习器收敛到更好的状态
- 将从其他拥有丰富数据的基础城市学到的知识转移到冷启动城市的推荐任务中
 - 即旨在从多个基础城市学习下一个 POI 搜索推荐器, 并将知识转移到多个目标 (冷启动) 城市, 以帮助提高这些城市的推荐服务质量
 - 关键是为基地城市和目标城市之间的知识转移量身定做一个合适的转移算法, 这面临着两个主要挑战
 - * 不同城市之间的共享数据极其有限, 使转移更具挑战性
 - 不同城市的 POI 没有交集
 - 一个城市内的大部分地图搜索记录都来自其本地居民, 这就严重削弱了不同城市间用户的交集
 - * 不同城市的用户的地图搜索模式表现出很大的差异性, 给推荐知识的传递带来很大的困难
- 提出了一个新的课程硬度感知元学习 (CHAML) 框架, 通过将元学习和非均匀抽样策略纳入下一个 POI 搜索推荐中来缓解数据稀少和样本多样性问题
 - 扩展了模型无知元学习 (MAML), 以帮助在有限的共享数据条件下向冷启动城市转移知识
 - 在元训练过程中设计了两个抽样策略组件, 即硬度感知元学习和城市级抽样课程, 以明确考虑样本多样性问题
 - * 利用硬样本挖掘的思想, 通过在条件采样期间同时考虑用户和城市级别的难度来增强元学习器, 迫使模型从更困难的示例组合中学习更多
 - * 将每一轮元训练分为两个阶段

- 以类似 MAML 的方式更新元学习器
- 在基于损失的标准下有条件地重新采样一组新的任务
- 提出借鉴课程学习 [40] 策略，以帮助提高高城市级多样性条件下元学习器的收敛率和泛化能力的元学习器
- 基本思想是通过教师判断的困难，以先易后难的范式为元学习者呈现训练任务，以帮助元学习者收敛到更好的状态
 - * 为每个基础城市预训练了一个教师推荐器，采用最佳有效分数来衡量城市级别的难度
 - * 利用这些知识在每个元训练步骤中为城市采样池设计课程。来自百度地图的两个真实世界地图搜索数据集的实验结果验证了我们提出的 CHAML 框架的有效性
- 本文的主要贡献：
 - 第一个探索城市转移下一个 POI 问题以搜索推荐并利用元学习范式解决该问题
 - 提出了一个新颖的课程硬度感知元学习 (CHAML) 框架，通过加强元学习器与用户和城市层面的硬样本挖掘和城市层面的课程学习，缓解冷启动城市的数据稀缺和样本多样性问题

16.POINTREC: A Test Collection for Narrative-driven Point of Interest Recommendation

(1) 研究内容：提出了一个在叙述驱动的场景中用于上下文兴趣点 (POI) 推荐的测试集合

(2) 创新点及要点：

- 集合中的请求是从社交共享网站手动收集的，并使用各种类型的元数据进行注释，包括位置、类别、约束和示例 POI。
 - 这些请求将从 POI 数据集中解决，这些数据集从流行的在线目录中收集，并进一步链接到地理知识库并通过相关的网络片段进行丰富。
 - 分级相关性评估是使用众包收集的，通过汇集手动和自动推荐，后者作为未来性能比较的基线。该资源支持开发用于端到端 POI 推荐以及自然语言请求的特定语义注释任务的新方法
- 目标是消除与提取上下文偏好和约束相关的困难，使它们更加明确，从而促进对新的上下文 POI 推荐方法的研究
- POINTREC 集合包括以下内容：
 - 695K POI 集合，跨越 23 个国家和 2K 多个城市，这些 POI 从流行的在线目录 (Yelp) 中收集，并进一步链接到地理知识库 (GeoNames) 并丰富了相关的网络片段
 - 一组来自真实用户的 112 条信息需求，每条都带有详细描述用户上下文和偏好的文本描述。这些自然语言描述丰富了元数据注释，并在可能的情况下链接到结构化知识库（包括类别、组、位置信息、约束和示例）
 - 通过众包收集的分级相关性评估

- TREC-CS 和 POINTREC 测试集合之间的主要区别：
 - TREC -CS 的信息需求是“综合的”，因为它们是通过众包使用虚构场景生成的。另一方面，POINTREC 的需求是真正有旅行意图的人的真实信息需求。
 - POINTREC 集合中的信息需求上下文和用户偏好均以自然语言详细描述，并已沿多个维度进行人工注释；在 TREC CS 的情况下，需要推断用户偏好。另一方面，POINTREC 的集合不包括过去的用户历史记录（除非在描述中引用了以前的经验），从而使其成为冷启动问题。
 - POINTREC 的 POI 集合覆盖 23 个国家/地区，而 TREC CS 仅处理北美城市。
- 结论：
 - 该集合主要旨在促进在基于叙述的场景中对 POI 推荐的研究，其中偏好和约束以自然语言给出
 - 这些已被手动识别并作为元数据注释提供，并且有可能提高推荐的质量
 - 用户偏好的自动提取、表示和解释是一项有趣且具有挑战性的自然语言理解任务，其本身并不局限于我们的设置；它也是一个中心组件，例如，在会话助手的上下文中。该数据集注释的信息需求集为该领域的研究提供了资源

17. STAN: Spatio-Temporal Attention Network for Next Location Recommendation

- (1) 研究内容：考虑非相邻位置和非连续访问为来理解用户行为，聚合来自用户轨迹的所有相关访问并从加权表示中召回最合理的 next-POI
- (2) 创新点及要点：
 - 提出了一个用于位置推荐的时空注意网络 (STAN)
 - STAN 明确利用轨迹上所有带有自注意力层的签到的相对时空信息。这种改进允许在非相邻位置和非连续签到之间进行点对点交互，并具有明确的时空效应
 - STAN 使用双层注意力架构，首先聚合用户轨迹内的时空相关性，然后考虑个性化项目频率 (PIF) 召回目标
 - 目前的模型仍未解决的问题：
 - 非相邻位置和非连续访问之间的相关性没有得到有效的学习
 - * 用户的移动性可能更多地取决于几天前访问过的相关位置，而不是刚刚访问过的不相关位置
 - 用户访问功能相关/相似的远距离位置并不少见。而大多数当前模型关注的是当前和未来步骤之间的空间和/或时间差异，而忽略了时空轨迹内的相关性
 - 先前实践的用于空间离散化的分层网格化对空间距离不敏感。基于网络的注意力网络聚合了相邻位置，但无法感知空间距离。彼此靠近的网格与那些不靠近的网格没有区别，会抛出大量空间信息。
 - 以前的模型广泛忽视了个性化项目频率 (PIF)。对同一地点的重复访问反映了频率，这强调了重复位置的重要性以及用户重访的可能性。由于记忆机制和归一化操作，以前的基于 RNN 的模型和自注意力模型很难反映 PIF

- 提出了 STAN，一种用于下一个位置推荐的时空自我注意网络。
 - 设计了一个自注意力层用于聚合历史轨迹中的重要位置，另一个自注意力层用于召回最合理的候选者，两者都考虑了点对点的显式时空效应
 - 自注意力层可以为轨迹内的每次访问分配不同的权重，克服了常用循环层的长期依赖问题。双层系统允许考虑 PIF 的有效聚合
 - 使用线性插值来嵌入时空转换矩阵来解决稀疏问题，这与 GPS 网格不同，它对空间距离很敏感。由于输入到模型中的所有签到的时空效应，STAN 可以学习非相邻位置和非连续访问之间的相关性
- 本文的贡献：
 - 提出了 STAN, 一种时空双向注意模型, 以充分考虑聚合相关位置的时空效应。STAN 是 POI 推荐中的第一个明确地结合了时空相关性来学习非相邻位置和非连续访问之间的规律的模型。
 - 用一种简单的空间离散化线性插值技术代替 GPS 网格化，可以恢复空间距离并反映用户的空间偏好，而不仅仅是聚合邻居。将此方法集成到 STAN 中以获得更准确的表示。
 - 提出了 PIF 的双向注意架构。第一层聚合轨迹内的相关位置以更新表示，以便第二层可以将目标与所有签到匹配，包括重复。
- 时空注意网络 (STAN) 包括：
 - 一个多模态嵌入模块，它学习用户、位置、时间和时空效应的密集表示
 - 一个自注意力聚合层，聚合用户轨迹内的重要相关位置，以更新每次签到的表示
 - 一个注意力匹配层，它从加权签到表示中计算 softmax 概率，以计算每个候选位置对下一个位置的概率
 - 一个平衡的采样器，它使用一个正样本和几个负样本来计算交叉熵损失
- 结论：
 - 提出了一个时空注意力网络，缩写为 STAN
 - 使用一个真实的轨迹示例来说明非相邻位置和非连续访问之间的功能相关性，并建议使用双向注意系统来学习轨迹内的显式时空相关性
 - 该架构首先聚合轨迹内的时空区间，然后调用目标。由于轨迹的所有表示都是加权的，因此目标的召回充分考虑了个性化项目频率 (PIF) 的影响。
 - 提出了一种用于匹配计算交叉熵损失的平衡采样器，优于常用的二元和/或普通交叉熵损失。
 - 在实验部分进行全面的消融研究、稳定性研究和可解释性研究
 - 建议用简单的线性插值技术代替用于空间离散化的层次网格方法，该技术可以在提供密集表示的同时反映连续的空间距离

18. Joint Spatio-Textual Reasoning for Answering Tourism Questions

- (1) 研究内容：回答寻求兴趣点 (POI) 建议的现实世界旅游问题 (回答推荐 POI 的问题)

(2) 创新点及要点:

- 开发了第一个联合空间文本推理模型，将地理空间知识与文本语料库中的信息相结合来回答问题
 - 开发了一个模块化的空间推理网络，该网络使用问题中提到的位置名称和候选答案 POI 的地理坐标，仅对空间约束进行推理
 - 将空间推理器与文本推理器结合在一个联合模型中，并对现实世界的 POI 推荐任务进行实验
 - 报告了在没有联合空间文本推理的情况下对现有模型的实质性改进
 - 第一个开发联合 QA 模型的人，该模型将外部地理空间知识的推理与文本推理相结合
- 提出了我们的空间-文本联合质量保证模型，用于返回需要文本和空间推理的问题的答案
 - 首先开发了一个模块化的空间推理网络，它使用问题中提到的位置名称的地理坐标，以及候选答案实体的地理坐标，只对空间约束进行推理
 - 它学会了将上下文距离权重与问题中提到的每个地点联系起来—这些权重将候选答案与它们各自的空间距离结合起来，为该答案生成一个”空间相关性”分数
 - 将空间推理器与文本 QA 系统结合起来，开发一个联合的空间-文本的 QA 模型。使用一个最近引入的 QA 任务来证明这个模型，其中包含寻求 POI（实体）答案的旅游问题
 - 它还包含一个实体评论的集合，作为回答这些问题的知识来源
 - 通过使用公开的 API 将问题中提到的位置映射到它们的地理坐标，为该任务提供地理空间知识
 - 同样候选答案的 POI 也被映射到它们的地理坐标上，作为数据集的一部分
- 本文的贡献：
 - 开发了一个空间推理器，该推理器使用地点和 POI 的地理坐标来推理问题中指定的空间约束
 - 使用一个简单的合成数据集证明，本文的空间推理器不仅能够推理出”近”和”远”的约束条件，而且还能够确定对推理没有用的位置参考
 - 开发了一个空间-文本质量保证模型，该模型使用为空间和文本推理设计的子网络将空间知识（地理坐标）和文本知识（POI 评论）融合在一起。
 - 证明了我们的空间-文本联合模型比只采用空间或文本推理的模型表现得更好
- 本文的工作与以下方向有关：
 - 地理信息系统
 - 地理空间查询
 - 问题回答的数字推理
 - 兴趣点（POI）推荐

- 用实验回答以下问题：
 - 模型在不同模板类别中的表现如何？
 - 该网络与不使用 DRL 的基线模型相比如何？
 - 该模型在处理干扰物位置（即与评分任务无关的位置）方面的表现如何？
- 结论：
 - 提出了第一个结合空间和文本推理的联合空间-文本质量保证模型
 - 在人工构建的（纯空间的）QA 数据集上的实验表明，我们的空间推理器能有效地进行训练以满足空间约束
- 未来的工作：希望支持对需要方向或地形推理的问题进行推理

19. Attentive sequential model based on graph neural network for next poi recommendation

(1) 研究内容：考虑用户的短期偏好随时间的动态变化，并更充分的利用签到序列中 POI 之间复杂的相关性和过渡性

(2) 创新点及要点：

- 提出了一个基于图神经网络（ASGNN）的注意力序列模型，用于准确推荐下一个 POI
 - 将用户的签到序列建模为图，然后使用图神经网络（GNN）来学习 POI 的信息性低维潜在特征向量（嵌入）
 - 采用个性化的分层注意力网络来利用签到序列中用户和 POI 之间的复杂关联，并捕捉用户的长期和短期偏好
 - 通过利用用户从其行为序列中获得的长期和短期偏好与 ASGNN 进行下一个 POI 推荐
- 现有的 POI 推荐方法面临以下两个挑战：
 - 如何充分挖掘用户的所有签到行为？在许多现有的方法中，用户的行为数据通常被建模为推荐的序列。然而，用户的签到行为通常包含许多有用的特征，这些特征还没有被充分地利用。此外，用户的签到序列可能会变得相当复杂，特别是当有大量的 POI 可用时，这使得从用户的签到序列中直接捕获用户的序列行为模式和偏好变得困难
 - 如何准确捕捉和利用用户的长期和短期偏好？用户的签到行为通常取决于长期和短期偏好，这在 POI 推荐中可能发挥不同的作用。具体来说，用户的长期偏好在一段时间内是相对稳定的，用户的短期兴趣往往会随着时间而动态变化。
- ASGNN 包括以下四个步骤
 - 将用户的历史签到数据构建为有向图。具体来说，每个签到序列可以被建模为一个有向图，其中节点包括用户节点和 POI 节点，图中的边分为从用户节点到 POI 节点的边和 POI 节点之间的边

- 使用 GNN 通过探索用户和 POI 之间丰富的互动/过渡来模拟用户的偏好和 POI 的特征。具体来说，采用了门控图神经网络（GGNN）将图中的节点嵌入到低维空间，并将其表示为潜在向量（嵌入）
- 设计了一个两层个性化的分层注意力网络，以获得用户对 POI 的个性化的长期和短期偏好，并以自适应的方式将其统一起来
- ASGNN 使用 softmax 层来预测用户的下一步行为，并对目标用户进行个性化推荐
- 主要贡献总结如下：
 - 出了一个名为 ASGNN 的新模型，它将用户的签到行为表示为图，并使用 GNN 来学习用户的行为模式和他们的偏好，以图本地化的方式进行下一个 POI 推荐
 - 设计了一个个性化的分层关注机制来捕捉用户的长期和短期偏好，并利用它们自适应地进行顺序推荐
- ASGNN 模型由四个主要步骤组成
 - 构建 POI 签到序列图
 - 特征表示学习
 - 长/短期偏好捕捉
 - POI 推荐
- 结论：
 - 提出了一种基于图神经网络（ASGNN）的注意力序列模型，用于下一个 POI 推荐
 - 本工作与之前的工作有两个主要方面的不同：
 - * ASGNN 采用 GNN 对用户的签到序列及其个性化行为模式进行有效建模
 - * ASGNN 使用 PHAN 自适应地捕获和利用用户的长期和短期偏好，以提高推荐性能
 - ASGNN 的 PHAN 组件被证明可以有效地捕捉用户的行为模式和偏好以进行准确的 POI 推荐
- 未来工作：计划利用异构 GNN [45] 充分探索各种辅助/辅助信息，例如时间上下文、元数据、序列相关性等，以进一步提高推荐性能。

20.ST-PIL: Spatial-Temporal Periodic Interest Learning for Next Point-of-Interest Recommendation

(1) 研究内容：通过学习时空周期性兴趣来推荐 next-POI

(2) 创新点及要点：

- 本文有关 POI 的模型：
 - 在长期模块中，学习了每日粒度的时间周期兴趣，然后利用 intra-level attention 形成长期兴趣
 - * 通过探索日常模式并通过内部关注来捕捉长期兴趣

- 在短期模块中，构造了各种短期序列，分别获取小时、区域和小时区域粒度的时空周期兴趣
 - * 提取各种短期序列来模拟顺序、空间、时间和时空模式
- 应用层间注意力来自动整合多个兴趣
- 提出了一个时空周期性兴趣学习网络 (ST-PIL) 用于下一个 POI 推荐
 - ST-PIL 采用长短期兴趣学习的结构，但充分利用时空上下文从历史签到中检索相关部分以进行周期性兴趣
 - 对于长期模块，根据称为星期几的时间上下文将用户的所有签到分成不同的序列。然后通过平均池化获得每日模式，并通过 intra-level attention 获得长期兴趣，用户每日粒度的时间流动性
 - 对于短期模块，我们通过称为时隙和 geohash 的上下文获得各种序列。相应地，LSTM 被部署以获得短期兴趣。该模块获取每小时、区域和每小时区域粒度的周期性
 - 对于整体表示，跨级关注和加权连接被用来自适应地结合所有的兴趣。一个多层感知器被用来获得候选兴趣点的最终概率
- 本文的贡献:
 - 充分考虑定期兴趣学习的空间-时间背景。具体来说，构建了每日、每小时、区域和每小时-现实粒度的周期性。
 - 提出两个层次的关注。级内注意从用户的日常模式中学习长期兴趣。级间关注整合了长期和短期的兴趣，以获得更好的整体代表性
- 未来的工作:
 - 设计一种更加自动化的建模方法来代替构建不同序列的预操作

21. Answering POI-Recommendation Questions using Tourism Reviews

- (1) 研究内容：采用问答方式 (QA) 从而回答兴趣点 (POI) 推荐问题,(使用描述 POI 的评论集来回答 POI 推荐的问题)
- (2) 创新点及要点:
 - 提出了一个特定任务的基线模型，它使用了一个三阶段的聚类-选择-排序架构
 - 首先对每个实体的文本进行聚类，以确定描述实体的典范句子
 - 使用一个神经信息检索 (IR) 模块，从大量的候选集合中选择一组潜在的实体
 - 使用一个具有更深层次的基于注意力的架构的检索器，从所选实体中挑选出最佳答案
 - 这种策略比纯粹的检索或纯粹的基于注意力的推理方法表现得更好
 - 第一个提出非结构化 QA 式的 POI 推荐任务，使用真实世界的旅游问题和 POI 评论
 - 收集了一个新的旅游问题数据集

- 选择使用旅游论坛和评论集来自动收获数据集
 - * 抓取了论坛的帖子及其相应的对话线程，以及包括发帖日期和时间的元数据
 - * 从一个流行的旅游论坛上抓取了每个城市的餐馆和景点的评论。酒店评论则是从一个流行的酒店预订网站上抓取的。实体的元数据，如地址、评级、设施等，也被收集起来
- 筛选问题
 - * 观察到，除了问题之外，论坛用户还发布旅行总结、关于度假期间所采取的服务的反馈、开放式的非实体搜索问题，如关于一个地方的天气和经济气候的查询等
 - * 使用基于关键词和元数据的高精度规则来过滤这类帖子
 - * 进一步删除了被论坛明确认定为”旅行报告”或”不适当”的帖子
- 实验中所回答的问题
 - 与其他更简单的基线相比，CsrQA 模型在这项任务中的表现如何？
 - CsrQA 基线与神经 IR 和神经 QA 模型相比如何？
 - 假阴性的影响是什么？
 - 候选空间的大小有什么影响？
 - 该系统在不同答案实体类型（类别）中的表现如何？
- 结论
 - 引入了一项新的任务，即根据描述实体的非结构化评论的集合，为给定的用户问题返回一个 POI 建议
 - 收获了一个超过 47,000 个问答对的数据集，这使得我们能够对模型进行端到端的训练
 - 本数据集的最大挑战之一是可扩展性。任务要求对每个问题的处理比大多数现有的 QA 任务多 500 倍，而且单个文件的大小也大得多
 - 提出了一个基于聚类-选择-排序架构的方法，它将神经 IR 和 QA 模型结合在一起，并作为这项任务的一个强大的基线

22.SNPR: A Serendipity-Oriented Next POI Recommendation Model

(1) 研究内容：只推荐意想不到的相关 POI, 而非推荐用户经常访问的 POI(面向偶然性的推荐)

(2) 创新点及要点：

- 提出了 Serendipity-oriented Next POI Recommendation 模型 (SNPR)
 - 研究的是一个有监督的多任务学习问题，目标是只推荐意想不到的相关 POI
 - 将定量的偶然性定义为在下一个 POI 推荐中对相关性和意外性的权衡，并设计了一个带有 Transformer 的专用神经网络来捕捉用户签到序列中 POI 之间复杂的相互依赖关系
- 面向偶然性的推荐的两个问题：

- 对于推荐中的偶然性的定义和评价指标还没有达成广泛的共识，因为偶然性包括情感层面。但研究者公认的原则是，相关性和意外性对偶然性都很重要
- 虽然通过偶然性引入的意外性缓解了乏味的推荐问题，但其直接的副作用是推荐与用户偏好的相关性降低了。在面向偶然性的推荐中，平衡意外性和相关性是至关重要的。
- SNPR 是一个有监督的多任务学习问题，突出表现在两个方面：
 - POI 推荐偶然性的定量定义，这导致了理想的训练基础事实
 - 用专门的深度神经网络代表用户签到序列中的 POI 之间的复杂关系，以提高推荐的相关性，而不损失意外性
- 本文的主要贡献：
 - 在 next-POI 推荐场景中定义了一个偶然性模型，并提供了一个考虑到相关性和意外性的偶然性的定量定义。该模型可以通过调整一个给定的超参数，灵活地在相关性和意外性之间做出权衡
 - 将下一个偶然性的 POI 推荐制定为一个有监督的多任务学习问题，即 SPNR，并在其中应用 Transformer 来捕捉 POI 之间复杂的相互依赖关系的专用神经网络
 - 从实验结果中发现了一个有趣的现象：当推荐列表规模较大时，意外性任务可以使相关性任务受益。本文的模型没有现有的面向偶然性的推荐方法所面临的相关性减弱的问题
- SNPR 的架构主要由四个部分组成：
 - 轨迹编码
 - 面向意外的建模
 - 面向相关性的建模
 - 偶然 POI 推荐和网络训练
- 结论：将偶然性引入 next-POI 推荐，以确保推荐满足用户的偏好，这些偏好由过去的行为和用户探索新位置的好奇所证明
 - 克服了现有解决方案在 next POI 推荐解决方案领域的普遍问题，即只关注用户的偏好，从而进行繁琐的推荐
 - 广泛的实验证明了所提出的 SNPR 模型在下一个 POI 推荐中的有效性，同时在定量偶然性之后考虑了相关性和意外性
 - 通过调整相关性意外权衡超参数，所提出的解决方案允许下一个 POI 推荐偏向于相关性或意外性

23.You Are What and Where You Are: Graph Enhanced Attention Network for Explainable POI Recommendation

- (1) 研究内容：以端到端方式解释 POI 预测的 POI 推荐器
- (2) 创新点及要点：

- 现有的具有浅层或深层架构的方法有两个主要缺点
 - 对于这些方法，个人的属性在很大程度上被忽略了。因此，如果不是不可能，也很难收集到足够的用户属性特征来完全覆盖可能的动机因素
 - 大多数现有的模型通过潜在的特征保留了用户或 POI 的信息，而没有明确强调突出的因素或信号
- 提出了 GEAPR，一个能够以端到端方式解释 POI 预测的 POI 推荐器
 - GEAPR 通过聚合不同的因素来学习用户表征，如结构背景、邻居影响、用户属性和地理位置影响
 - GEAPR 利用三重关注机制来量化不同因素对每个结果建议的影响，并对模型的可解释性进行全面分析
- 现有模型的两个普遍缺陷：
 - 可解释的 POI 访问动机分析不足
 - * 对于动机分析，现有方法的排名功能只是融合了多模式的信息，而没有明确地量化或解释哪些模式比其他模式更重要，哪些模式不那么相关
 - 对具有不同背景的用户缺乏属性研究
 - * 现有的 POI 推荐方法在很大程度上忽略了用户属性的研究，有必要结合用户属性特征来完全覆盖可能的动机因素
- 提出了一个用于可解释的 POI 推荐的图形增强注意力网络（GEAPR）
 - 以一种自适应和可解释的方式推荐 POI
 - GEAPR 不仅利用了地理和社会信息，而且还利用了用户的个人属性，并在此过程中提供了一个端到端的推荐理由
 - 具体来说，将可能的动机分解为四个因素：
 - * 结构性背景
 - * 邻居和朋友的影响
 - * 用户属性
 - * 地理定位的影响
 - 本文的贡献
 - * 提出 GEAPR，一个能够以端到端方式解释 POI 预测的 POI 推荐器。关注四个因素，即结构背景、邻居影响、用户属性和地理位置影响，并以数值作为特征显著性指标量化其影响
 - * 用户属性在 GEAPR 中得到了考虑，是第一个将属性纳入 POI 推荐的工作
 - * 注意力机制被用来解决推荐的可解释性，其方法是找到与其他特征相比在 POI 推荐中更有影响力的重要因素
 - GEAPR 使用了三种不同的架构，为用户动机方面的三个因素定制
 - * 一个基于密集神经网络的结构性语境编码器被用来学习结构性语境
 - * 一个基于图神经网络的注意力友谊编码器被用来模拟邻居的影响

- * 一个基于注意力的潜在因素化机被用来保存属性的相互作用
- 未来的工作:
 - * 通过语义构建 POI 图并应用图挖掘算法
 - * 学习复杂信息需要更好的方法来保存非线性地理定位特征

24.LightMove: A Lightweight Next-POI Recommendation for Taxicab Rooftop Advertising

(1) 研究内容: 预测出租车的所前往的下一个位置, 以更好地准备基于地点的有针对性的广告

(2) 创新点及要点:

- 提出了一种轻量级但准确的基于深度学习的方法来预测出租车的下一个位置, 以更好地准备基于地点的人口统计信息的有针对性的广告
 - 考虑到 next-POI 推荐数据集经常是稀疏的, 设计了基于神经常微分方程 (NODEs) 的模型, 已知它对稀疏/不正确的输入具有鲁棒性, 并有一些改进
 - 本文的模型 LightMove, 与最先进的模型相比, 在对各种数据集进行评估时, 具有更大的预测准确性, 更少的参数数量, 和/或更少的训练/推理时间
- 提出的模型由四个模块组成:
 - 一个有注意力的短期历史模块
 - 一个没有注意力的长期历史模块
 - 一个主神经常微分方程 (NODE) 层, 从初始隐藏向量 $h(0)$ 生成最后的隐藏向量 $h(1)$
 - 一个分类器, 预测接下来的位置
- 本文的贡献:
 - 设计了一个基于 NODEs 的轻量级但准确的 next-POI 推荐模型。
 - 用各种技术设计了自己的 NODE 层:
 - * 连续的 GRU 单元
 - * ODE 状态跳跃
 - * 自适应参数生成

25.SAR-Net: A Scenario-Aware Ranking Network for Personalized Fair Recommendation in Hundreds of Travel Scenarios

(1) 研究内容: 为访问不同场景的用户提供个性化的推荐服务

(2) 创新点及要点:

- 有两个关键问题需要:
 - 由于不同场景的流量特征, 例如个体数据规模或代表性主题, 存在显著差异, 因此训练一个统一的模型来服务所有人是非常具有挑战性的

- 在推广期间，由于人工干预，一些特定项目的曝光会被重新加权，导致有偏差的日志，这会降低使用这些有偏差的数据训练的排名模型
- 提出了一种新颖的场景感知排名 网络 (SAR-Net)
 - 通过两个特定的注意力模块学习用户的跨场景兴趣，从而从不同场景中获取丰富的数据，这两个模块分别利用场景特征和项目特征来调制用户行为特征
 - 将前一模块的编码特征作为输入，采用特定场景的线性变换层，进一步提取特定场景的特征，接着是两组 debias 专家网络，即特定场景专家和场景共享专家。他们独立输出中间结果，通过多场景门控模块进一步融合成最终结果
 - 为了缓解人工干预造成的数据公平性问题，提出了公平系数 (FC) 的概念来衡量单个样本的重要性，并利用它来重新权衡 debias 专家网络中的预测
- 多场景建模问题，通常有三种解决方案
 - 为每个场景训练单独的排名模型
 - 用所有场景数据训练一个统一的排名模型
 - 使用多任务学习框架，同时输出多个预测结果，每个结果用于每个场景
- 本文的贡献：
 - 提出了一种新颖的 SAR-Net，可以在给定场景特征和物品特征的情况下预测用户的跨场景兴趣，并自适应地提取不同场景下的重要特定信息。
 - 研究了推荐系统中由人工干预引起的数据公平问题，并通过网络结构和损失函数的设计提出了一个简单而有效的解决方案
- 结论：
 - 提出了一种新颖的场景感知排名 网络 (SAR-Net) 来解决遇到的两个问题，即多场景建模问题和数据公平问题
 - SAR-Net 通过两个特定的注意力模块学习用户的跨场景兴趣，从而从不同场景中获取丰富的数据
 - 采用场景特定的转换层来进一步提取场景特定的特征，然后是两组去偏专家网络
 - 上述中间结果通过多场景选通模块融合到最终结果中
 - 提出了公平系数的概念来衡量个体样本的重要性，并用它来重新衡量去偏专家网络中的预测
- 未来的工作：研究引入更多用户细粒度行为的影响

26.PREMERE: Meta-Reweighting via Self-Ensembling for Point-of-Interest Recommendation

- (1) 研究内容：用自适应的加权方案处理用户或 POI 的不同特征
- (2) 创新点及要点：
 - 提出 PREMERE，一种基于元学习的自适应加权方案

- 元数据通常是元学习所需要的，但在 POI 推荐中很难获得，所以通过自集成来自生成元数据
- 元模型架构被扩展以处理签到的稀缺性
-
- 依赖于 user-POI 签到矩阵的类别不平衡和噪声值可能导致 POI 推荐的性能不佳，所存在的问题：
 - 矩阵非常稀疏，只有一小部分条目（约 0.1%）是非零的
 - 一个零条目并不一定表示不感兴趣，因为用户可能会遗漏或忘记分享他们对感兴趣的 POI 的访问
- 提出了一个自适应的加权方案，称为 PREMERE
 - PREMERE 从数据中学习对样本进行重新加权；对于每个样本，它产生在优化过程的当前阶段最适合的权重
 - 将元学习应用于 POI 推荐的样本复权是非常具有挑战性的，因为对应于精确的用户偏好或用户轨迹的元数据实际上是很难获得的
 - 本文的主要目标是缓解在 POI 推荐中缺乏元数据的问题，以便对基于元学习的样本进行重新加权
 - 利用自集成，更具体地说是时间集成来生成元数据
 - PREMERE 涉及两个模型：推荐模型和元模型（即加权函数）
- 本文的贡献：
 - 提出了 PREMERE，这是一种元学习方法，采用自适应样本重新加权来减轻输入数据的类别不平衡和噪声值。此外，还开发了一种新的元模型架构 PREMIERENET 来解决类不平衡问题
 - 首次尝试将元学习用于 POI 推荐
 - 通过时间集成通过其自身生成来缓解元数据的缺失，该集成用于更新了解用户和 POI 特征的 PREMERE-NET 模型
- 结论：
 - 提出了 PREMERE，这是一种基于元学习的新型 POI 推荐样本重加权方案
 - 元模型架构 PREMERE-NET 被扩展为使用精心设计的上下文数据和处理正样本的单独流程
 - 作为 POI 推荐的一个关键问题，元数据的缺失通过时间集成的自生成技术得到了解决
 - 通过将 PREMERE 整合到基于 DNN 的 POI 推荐算法中，进行了广泛的评估
 - 总体而言，PREMERE 可以应用于任何 DNN 架构，并有望提高 POI 推荐性能

27.Out-of-Town Recommendation with Travel Intention Modeling

- (1) 研究内容：为前往外地的用户提供从未去过的地点的 POI 推荐

(2) 创新点及要点:

- 外地前往 POI 的行为不仅取决于用户的家乡偏好, 还取决于用户的旅行意图
- 提出了一个 TRAVelINtention 感知的 Out-of-town Recommendation 框架, 名为 TRAINOR
 - 提议的 TRAINOR 框架在三个方面与现有的外地推荐器不同
 - * 探索图神经网络来表示用户的家乡签到偏好和外地签到行为中的地理限制
 - * 用户特定的旅行意图被表述为将家乡偏好和一般旅行意图结合在一起的聚合, 其中一般旅行意图被视为可以通过神经主题模型 (NTM) 学习的内在意图的混合
 - * 分别采用非线性映射函数和矩阵分解方法来传递用户的家乡偏好和估计外地 POI 的表示
 - 设计了一个基于门控图神经网络 (G-GNN) 的用户偏好表示模块, 以探索用户在家乡签到中编码的潜在结构信息
 - 通过注意力网络进行汇总后, 用户的家乡偏好通过非线性映射函数, 即多层感知器 (MLP) 进一步转移到外地偏好。通过这种方式, 可以直接捕捉到从家乡到外地的兴趣漂移
 - 通过开发神经主题模型 (NTM) 和用户特定的旅行意向汇总, 设计了一个旅行意向发现模块
 - 假设每一个城外签到活动都可以从潜在的主题混合物中提取, 该混合物可以通过高斯 Softmax 构造进一步生成
 - 采用变异推理来发现用户的一般旅行意向, 而无需额外的监督
 - 上述用户的家乡偏好被整合到披露的通用旅行意向中, 通过另一个注意力网络生成用户的特定旅行意向
 - 还通过利用矩阵分解 (MF) 方法来表示用户的外地偏好, 并通过考虑城外景点之间的地理邻近性来丰富这种城外偏好
 - 以端到端的方式采用了联合学习方法来产生训练有素的推荐者。
- 传统的 POI 推荐系统 (POI RSs) 无法做出适当的推荐来解决这种困难的冷启动问题。其原因是
 - 由于家乡偏好和外地行为之间的差距 (即兴趣漂移), 个人的家乡偏好不能直接用于外地推荐
 - 旅行意向, 倾向于影响外地签到行为, 在这些 POI RSs 中往往被忽略
- 本文的贡献:
 - 通过对用户复杂的旅行意向进行建模来研究外地的推荐问题
 - 设计了一个框架 TRAINOR, 能够全面地捕捉用户的家乡偏好、用户从家乡到外地的兴趣漂移、外地的地理影响和用户的旅行意向
- 结论:
 - 通过旅行意图建模研究了外地推荐问题。提出了一个数据驱动的框架 TRAINOR, 通过综合考虑用户偏好、兴趣漂移、旅行意图和外地地理影响来学习外地推荐者。

- 为了调查用户的家乡偏好, 利用了 G-GNN 模型
- 另一方面, 用户的外地偏好以集体方式估计, 并通过地理 GCN 进行丰富。之后, 设计了一个偏好转移模块, 通过 MLP 将家乡偏好映射到外地登记行为。此外, 为了了解用户复杂的旅行意图, 开发了基于 NTM 的用户特定旅行意图发现模块
- 通过联合最小化复合损失, TRAINOR 可以以端到端的方式产生学习的推荐器

28.Pre-training Context and Time Aware Location Embeddings from Spatial-Temporal Trajectories for User Next Location Prediction

(1) 研究内容: 通过预训练位置嵌入从而进行 POI 推荐

(2) 创新点及要点:

- 现有的在轨迹上预训练的位置嵌入大多基于分布式词表示, 将位置的各种功能混合到一个潜在表示向量中
- 提出了一个上下文和时间感知位置嵌入 (CTLE) 模型
 - 计算一个位置的表示向量, 并考虑其在轨迹中的特定上下文邻居, 通过这种方式, 可以适当地处理位置的多功能属性
 - 为了将轨迹中的时间信息整合到位置嵌入中, 提出了一个微妙的时间编码模块和一个新的预训练目标, 进一步提高了位置嵌入的质量
- 建立一个预训练模型, 该模型能够根据特定的上下文邻居自适应地为位置生成嵌入向量
 - 提出了一种新颖的上下文和时间感知位置嵌入 (CTLE) 模型。目标位置的嵌入向量不是分配一个潜在向量作为每个位置的最终表示, 而是通过其上下文位置的编码向量的参数化映射函数来计算, 通过这种方式将位置的特定于上下文的功能合并到它们的嵌入向量中
 - 使用双向 Transformer 编码器, 并采用 BERT 中引入的掩蔽语言模型 (MLM) 预训练目标对用户轨迹中的顺序相关性进行建模
 - 为了将独特的时间信息合并到轨迹中, 设计了一个微妙的时间编码模块来模拟位置之间的相对访问时间差异
 - 提出了一种新颖的 Masked Hour (MH) 预训练目标, 以从其访问时间分布中提取位置的功能
- 本文的主要贡献:
 - 提出了一种上下文位置嵌入模型 CTLE, 能够根据目标位置的特定上下文自适应地生成嵌入向量。因此, 可以区分不同上下文环境下位置的可变功能
 - 提出了一个微妙的时间编码模块和一个新的预训练目标来对轨迹中时间信息的两个方面进行建模, 提高我们的模型对位置特征的理解
- CTLE 模型的架构主要由三个部分组成:
 - 编码层, 将时间编码向量与位置的编码向量融合, 从相对访问时间差中提取信息
 - 双向 Transformer 编码器, 作为一个映射函数, 用于计算目标位置的嵌入, 给定其特定的上下文邻居

- 预训练目标，通过对目标位置和上下文之间的共现概率以及对目标的绝对访问时间进行建模，将位置的特征信息纳入其嵌入中

29.MFNP: A Meta-optimized Model for Few-shot Next POI Recommendation

(1) 研究内容：对签到记录很少的用户进行 POI 推荐

(2) 创新点及要点：

- 提出了一种新颖的元优化模型 MFNP，可以快速适应签到记录很少的用户
 - 针对冷启动问题，将精心设计的用户特定和区域特定任务无缝集成到元学习中，从而可以通过区域无关的个人偏好和区域相关的人群偏好的合理融合来捕获区域感知的用户偏好
 - 在对依赖于区域的人群偏好进行建模时，采用基于集群的自适应网络来捕获相似用户的共享偏好以进行知识转移
- next-POI 推荐需要考虑用户兴趣漂移的现象，因为用户在不同区域可能有不同的偏好。
- 由于相似用户总是遵循相似的行为模式，因此应该从相似用户而不是所有用户那里获得人群偏好以避免分歧
- 在考虑用户兴趣漂移现象的同时研究了 few-shot next POI 推荐，并提出了 Few-shot Next 的元优化模型 POI 推荐（简称 MFNP）
 - 为每个用户构建了一个元学习器，以根据他们自己的签到记录提供个性化的模型
 - 除了特定于用户的任务外，模型还包括特定于区域的任务，以捕获目标区域的区域相关人群偏好
 - 为了更好地在相似用户之间传递共享偏好
 - * 通过聚类对所有用户进行分组，并采用自适应网络来平衡不同用户群的人群偏好的重要性
 - * 为了解决数据稀疏问题，提出了一种融合方法来自适应地融合个人偏好和区域相关的人群偏好，从而可以通过知识转移对区域相关的用户偏好进行建模
- 本文的主要贡献：
 - * 提出了一种新颖的元优化模型，是第一个利用元学习进行小样本下一个 POI 推荐的模型
 - * 通过考虑用户兴趣漂移，集成了精心设计的用户特定和区域特定任务，使得区域级用户偏好可以通过自适应融合的个人和人群偏好的转移知识来捕获
 - * 提出了一个基于集群的自适应网络来模拟更有意义的区域相关人群偏好
 - * 通过对聚类用户上不同类型的人群模式进行融合，保证了相似用户之间的共享偏好，从而避免了不同类型用户之间的分歧
- MFNP 模型的整体架构：
 - * 将每个用户的签到序列拆分为支持集和查询集

- * 在使用元参数初始化本地参数后, 通过基本推荐系统对用户的偏好进行建模。在用户特定偏好建模模块中, 根据用户的个人签到记录使用地理详细的 LSTM 对用户的区域无关偏好进行建模
 - * 在特定区域偏好建模模块中, 首先定位用户所属的相应用户组。然后从特定区域的签到中学习区域相关的人群偏好, 并通过时间和空间上下文将它们合并
 - * 使用支持集在本地训练推荐系统, 并使用查询集全局更新元参数
- 结论:
- * 考虑用户兴趣漂移现象的同时研究了 few-shot next POI 推荐
 - * 为每个用户构建一个元学习器, 根据他们自己的签到记录提供个性化的模型
 - * 提出了一个特定于区域的偏好模块来捕获与目标用户在同一区域中的相似用户的区域相关人群偏好
 - * 提出了一种自适应方法来将这些偏好与空间和时间因素相结合

30. Point-of-Interest Type Prediction using Text and Images

(1) 研究内容: 使用发布时可用的文本和图像的多模态信息来推荐 POI

(2) 创新点及要点:

- 使用来自发布时可用的文本和图像的多模态信息来进行 POI 推测
 - 使用伴随文本消息的图像丰富了当前可用的 POI 类型预测数据集
 - 从每种模态中提取相关信息, 以有效捕获文本和图像之间的交互
 - 提供了详细的分析, 以阐明跨模态交互以及最佳性能模型的局限性
- 本文的贡献:
 - 用图像丰富了社交媒体帖子和 POI 类型的公开可用数据集
 - 提出了一个多模态模型, 该模型将文本和图像组合在两个层次上使用:
 - * 模态门来控制文本和图像所需的信息量
 - * 一种用于学习跨模式交互的交叉注意机制
 - 提供深入分析以揭示模型的局限性并揭示 POI 类型的跨模式特征
- 结论:
 - 介绍了一个使用来自地理符号学、视觉符号学和文化地理学研究的社交媒体帖子中的文本和图像进行多模式 POI 类型分类的研究
 - 用图像丰富了一个公开可用的数据集, 提出了一个多模态模型, 使用:
 - * 一个门机制来控制来自每个模态的信息流
 - * 一种交叉注意机制, 用于对齐和捕获模态之间的交互
 - 模型在 POI 类型预测方面实现了最先进的性能, 显着优于之前的纯文本模型和具有竞争力的预训练多模态模型

。

- 未来的工作
 - 对 POI 类型和用户信息进行更精细的预测，为模型提供额外的上下文
 - 模型还可以用于对社交帖子中自然出现文本和图像的其他任务进行建模

31.EDGE: Entity-Diffusion Gaussian Ensemble for Interpretable Tweet Geolocation Prediction

(1) 研究内容：利用推文进行可解释的地理位置预测

(2) 创新点及要点：

- 提出了一个推特地理位置预测框架，EDGE (Entity-Diffusion Gaussian Ensemble)
 - 提供的预测既准确又高度可解释，而不需要任何额外的背景信息，如用户资料和位置历史
 - 在 EDGE 中，通过学习概率生成模型，将地理位置问题作为一个中性网络优化问题
 - 与现有的工作相比，EDGE 有两个独特的特点
 - * 推理建立在挖掘非地理标志实体和地理标志实体之间的相关性上，通过在构建的图神经网络上扩散它们的语义嵌入（实体扩散）
 - * 每个预测结果被表示为高斯混合物而不是具体的地理坐标（高斯集合），将地理位置问题投射为一个中性网络优化问题
- EDGE 面临的两个挑战：
 - 从短推文中利用的有限的地理指示信息，以及推文的自由写作风格，这与传统的 NLP 工具并不兼容
 - 如何产生准确和高度可解释的预测
- EDGE 由三个无缝集成的模块组成：
 - 实体嵌入提取和扩散
 - 注意力聚集
 - 混合分布学习
- 本文贡献：
 - 提出了 EDGE，一个新颖的推文地理位置预测框架，它提供的预测既准确又可解释，而不需要在文本中提到地点或任何额外的上下文信息
 - 提出了 entity2vec 来提取推文中出现的命名实体的嵌入，而不是把它们当作独立的词的组合
 - 开发了一种实体扩散机制，通过在图卷积网络上扩散空间特征信息来捕捉非地理指示性实体和地理指示性实体之间的相关性。这种设计使其能够学习每个实体的空间平滑嵌入
 - 设计了一个注意力机制，在为每条推文提取空间平滑嵌入的同时，对共同出现在同一推文中的实体的重要性进行加权。学习了一些参数来权衡细粒度的地理指示性实体和粗粒度的地理指示性实体

- 以端到端的方式训练 EDGE，以最大限度地提高地理标记的推文位于其相关位置的可能性。EDGE 返回一个高斯混合物作为预测结果，其通用性足以预测任何大小区域内的推文位置
- 结论：
 - 介绍了一种新颖的推文地理定位预测框架 EDGE:
 - * 无需任何额外的上下文信息即可提供准确且高度可解释的预测
 - * EDGE 有两个显着特点：
 - 推理建立在挖掘非地理指示实体和地理指示实体之间的相关性之上，通过在构建的图神经网络上扩散它们的语义嵌入
 - 每个预测结果表示为高斯混合而不是特定的地理坐标

32. Personalized POI Recommendation: Spatio-Temporal Representation Learning with Social Tie

(1) 研究内容：用神经网络来推荐个性化 POI

(2) 创新点及要点：

- 提出了一种用于个性化和连续 POI 推荐的统一时空神经网络框架，名为 PPR
 - 利用用户的签到记录和社交关系，通过联合嵌入和序列建模来推荐个性化 POI 用于查询用户
 - PPR 通过在异构图中联合建模 User-POI 关系、序列模式、地理影响和社会关系来学习用户和 POI 表示
 - 使用基于 LSTM 模型设计的时空神经网络对用户个性化序列模式进行建模用于个性化 POI 推荐
- 构建 PPR 的具体步骤：
 - 通过构建异构图对用户-兴趣点关系、顺序效应、地理影响和社会关系进行联合建模
 - 通过向具有低入/出度的节点添加二阶邻居来开发致密化技巧，以缓解数据稀疏问题
 - 通过将密集异构图嵌入到共享的低维空间中来学习用户和 POI 表示
 - 为了更好地捕捉用户动态和个性化偏好，设计了一个时空神经网络，将用户嵌入、POI 嵌入和 POI 类别作为个性化序列输入连接到网络中
- 基于位置的 POI 推荐面临三个主要挑战：
 - 数据的稀缺性
 - 情境因素
 - 动态和个性化的偏好
- 本文的主要贡献：
 - 提出了一种新颖的 PPR 模型，用于个性化 POI 推荐，该模型结合了用户的签到记录和社会关系。通过联合考虑用户-兴趣点关系、顺序模式、地理效应和社会关系来构建异构图，以学习用户和兴趣点的表示

- 提出了一种时空神经网络，通过连接用户、POI 嵌入和 POI 类别来模拟用户的动态和个性化偏好，以生成个性化的行为序列
- 结论：
 - 提出了一种新颖的时空表示学习模型，用于个性化 POI 推荐
 - * 通过结合用户-兴趣点关系、顺序效应、地理效应和社会关系，构建了一个异构网络
 - * 利用嵌入技术来学习用户和 POI 的潜在表示
 - * 鉴于 RNN 最近在序列预测问题上取得的成功，为时空网络提供连接的用户和 POI 嵌入序列，以捕获用户的动态和个性化偏好
 - * 探讨了每个因素在提高推荐性能方面的重要性
 - * 观察到顺序效应、地理效应以及用户的动态和个性化偏好在 POI 推荐任务中起着至关重要的作用

33. DeepAltTrip: Top-k Alternative Itineraries for Trip Recommendation

(1) 研究内容：从一个城市的大量候选 POI 中找到有序的兴趣点 (POI) 序列，从而为用户推荐路线，基于学习的技术来推荐多个备选行程

(2) 创新点及要点：

- 提出了一个基于深度学习的框架，称为 DeepAltTrip
 - 可以为给定的来源和目的地 POI 推荐前 k 个备选行程。这些备选路线不仅是过去用户采用的流行路线，而且是彼此不同 (多样化) 的路线
 - DeepAltTrip 程序包括两个主要部分
 - * 行程网 (ITRNet)，它通过使用图自动编码器和两个 (前向和后向) LSTM 来估计行程中 POI 的可能性
 - * 路线生成程序，生成 K 个不同的行程，通过使用 ITRNet 获得的相关 POI，提出了 DeepAltTrip 的两种变体：
 - 第一个是基于 LSTM 的行程生成技术
 - 第二个是基于采样的技术，它提供了适应用户约束的灵活性
 - 对于路线生成步骤，提出了一种新颖的采样算法，可以无缝地处理各种用户定义的约束
 - 是第一项从历史行程中学习，为用户提供一套备选行程的工作
- 本文的贡献：
 - 首次提出了基于学习的算法，即 DeepAltTrip-LSTM 和 DeepAltTrip-Samp，利用历史行程推荐 k 个备选行程，而不需要任何明确的流行度或多样性模型。
 - DeepAltTrip-Samp 的一个独特优势是，它可以无缝地支持对生成的行程的额外约束
- 结论：

- 提出了两种基于深度学习的方法，可以学习为给定的来源和目的地推荐前 k 个替代路线
 - * 开发了路线网络 (ITRNet)，通过使用图形自动编码器和两个（前向和后向）LSTM 来估计路线上 POI 的可能性
 - * 基于 ITRNet，我们开发了两个变体，DeepAltTrip-LSTM 和 DeepAltTrip-Samp，使用历史旅行推荐 k 个替代路线，而不需要任何明确的流行度或多样性建模
 - * DeepAltTrip-Samp 解决方案还可以简单地结合各种用户定义的约束
- 未来的工作；我们计划结合用户个性化，利用查询用户访问的历史路线的信息

34. Mobility-based Individual POI Recommendation to Control the COVID-19 Spread

- (1) 研究内容：根据用户喜好推荐 POI 同时减少新冠感染风险
- (2) 创新点及要点：
 - 提出了一种个人级别的 POI 推荐系统
 - 可以根据用户的喜好向用户推荐场所，同时可以尽可能减少感染
 - 系统的关键思想是，被感染的风险随着之前访问过该场所的唯一客户的数量而增加，并且在特定时间段内访问一个不太拥挤的地方更安全
 - 结论：
 - 提出了一种简单但有效的方法来推荐可以显著减少感染传播同时满足所有登记需求的场所
 - 提出的系统还具有灵活性和可扩展性，可以根据当地的 COVID-19 情况进行定制

35. Point-of-Interest Recommendation for Users-Businesses with Uncertain Check-ins

- (1) 研究内容：对于不确定的签到的情况的 POI 推荐（由于集体 POI 的存在（多个单独 POI 的聚集地），通常会获得不确定的签到）
- (2) 创新点及要点：
 - 对于集体 POI 所获得不确定签到情况面临的问题：
 - 一方面，由于过渡消失问题，这种对集体 POI 的不确定签到阻碍了对用户更准确的下一个 POI 推荐
 - 另一方面，由于企业之间复杂的竞争与合作关系，集体 POI 的存在给企业选择定位于哪些集体 POI 带来了挑战
 - 提出了有利于 Users-Businesses 的新型位置服务解决方案
 - 对于用户，建议配备类别和位置感知编码器的 STSP，通过融合丰富的上下文特征来提供更准确的下一个 POI 预测
 - 对于企业，从签到记录中探索它们的竞争和合作关系，并据此推导出一个企业的生存环境 (LE)。通过利用 LE 为企业提供了选址洞察力，旨在带来更多利润

- 在基于位置的社交网络 (LBRS) 中, 基于集体 POI 的不确定签到的历史数据, 为用户和企业带来好处
 - 进行了广泛的分析, 探索用户在不确定的签到中的流动性和集体 POI 的特点, 以指导解决方案的设计
 - 对于面向用户的位置服务, 贡献了 STSP 框架, 该框架配备了类别和位置感知编码器, 通过融合顺序、时间、空间和受欢迎程度的影响, 完全捕捉到用户对类别和位置的偏好
 - 两个编码器被联合学习以实现下一个 POI 的推荐, 其中预测的类别有助于减少 POI 的搜索空间, 以及缓解因不确定的签到而加剧的极端稀疏问题
 - 关于以商业为导向的位置服务, 这是由集体 POI 的存在所激发的, 试图从签到记录中探索集体 POI 中商业之间的竞争和合作关系
 - 通过分析上述关系, 进一步得出了生活环境 (LE) 的度量, 以帮助决定是否在一个集体 POI 中为企业定位
- 本文的主要贡献:
 - 首次启动更全面的定位服务, 该服务有利于 LBRS 社区的用户和企业。集体 POI 的存在不仅为用户生成下一个 POI 推荐, 还为企业提供选址建议
 - 设计了 STSP 框架, 通过融合丰富的上下文特征, 为不确定的签到用户提供更准确的下一个 POI 推荐
 - 通过基于用户签到记录的竞争和合作关系, 得出企业的 LE。它为商家的选址提供了启示, 因为将商家定位在一个具有良好 LE 的集体 POI 内, 可以带来更多的签到和利润
- 不确定签到的 POI 推荐所面临的挑战:
 - 学习完整的上下文特征, 例如顺序规律性
 - 预测集体 POI 中的单个 POI, 因为它们在用户的签到记录中未被观察到
- 结论:
 - 提供了 POI 推荐的解决方案, 这对 LBRS 社区的用户和企业都有好处
 - 设计了 STSP 框架, 配备了类别和位置感知编码器, 以分别捕获用户对类别和位置的偏好。然后联合学习这两个编码器, 为签到不确定的用户实现下一个 POI 推荐
 - 通过巧妙地容纳从签到记录中探索的竞争和合作关系, 得出一个企业生存环境的度量, 用于决定是否将企业定位在集体 POI 中

36. DynaPosGNN: Dynamic-Positional GNN for Next POI Recommendation

(1) 研究内容: 考虑用户当前轨迹之后的下一个位置的具体的到达时间或预测时间

(2) 创新点及要点:

- 提出了动态位置图神经网络 (DynaPosGNN)
 - 一种考虑离线用户活动中特定到达时间的新型下一个 POI 推荐模型

- DynaPosGNN 可以通过分析到达时间与称为 “User-POI 图” 和 “POI-POI 图” 的两个空间动态图之间的相关性来预测用户的下一个位置
- next-POI 推荐任务中的现有挑战：
 - 以前的方法预测用户最后一次访问位置之后下一步要去哪里，这没有考虑预测时间
 - 现有的用于表示空间 POI 图的方法通常会忽略访问历史的动态性。现有方法在以图的形式表示 POI 之间的关系时，通常包括单条边上 POI 之间的连续访问次数和转移次数，不包括每次访问发生时间的信息。例如，对 POI 进行了多次访问，这些访问可能是非常古老的，也可能是最近的。缺少有关访问某个位置的最新信息，即使它可能是预测用户下次访问的重要信息
- 本文的贡献：
 - DynaPosGNN 是一个更现实 next-POI 推荐模型，用户期望在特定时间点访问，而不是简单地预测当前访问后去哪里，提出的模型根据预测时间仔细考虑了相关因素
 - 使用多边图表示来考虑用户访问历史的动态。与现有方法不同，利用 POI 节点之间的多条边，并将每次访问历史表示为不同的边。这是因为 POI 之间的连续访问历史可能发生在很久以前，或者最近，或者周期性地发生。将这些机制应用于包含每个用户访问历史的 “user-POI 图” 和包含整个用户集访问历史的 “POI-POI 图”
- 结论：
 - 处理的问题是考虑到用户到达某个位置的特定未来时间的 next-POI 推荐
 - 为了实现推荐的高精度，将两个具有多边表示的动态图应用于 DynaPosGNN
 - 通过给定的预测时间调整以用户为中心的轨迹和公共运动记录的影响
 - 对两个图的消融研究说明了一种基于本文的方法显着互补的有效推荐机制
- 未来的工作：将人类移动预测问题重新定义为轨迹推荐
 - 在当前用户位置之后推荐几组连续的下一个 POI
 - 期望用户的详细上下文和行为语义信息可以通过准确预测的未来轨迹而不是单个下一个 POI 得出