

# POI 推荐分类

## 1. POI 分类

### (1) RNN based models

- Empowering Next POI Recommendation with Multi-Relational Modeling(MEMO)
  - 考虑关系异质性 (relational heterogeneities) 和用户与 POI 之间的随着时间的推移相互影响从而进行 next-POI 推荐
  - 提出了一个新的框架 MEMO, 有效地利用了多网络表示学习模块的异构关系, 并明确地将跨时的 user-POI 的相互影响与耦合的递归神经网络结合起来
  - 关系模型 (MEMO) :
    - \* 开发了一个基于多图卷积网络 (GCNs) 和 self-attention 的多关系建模模块, 从而利用不同的 user-user 社会关系和 user-POI 关系 (异构关系), 即将每一种关系映射到相应的网络, 以学习特定的关系表征; 然后采用 self-attention 机制, 从不同的关系类型中聚合用户表征
    - \* 设计了一个基于耦合的递归神经网络 (RNN) 的 user-POI 相互影响建模组件相互更新对方的表征, 从而捕捉用户和 POI 之间随时间推移的相互影响
  - 本文的关系异质性主要是考虑 Social Influence, 而其考虑用户的偏好以及 POI 的潜在状态主要是考虑 Semantic Effect, 模型有考虑 Temporal Influence, Geographical Influence 但不是其研究重点

### (2) LSTM models

- Basic LSTM
  - Personalized POI Recommendation:Spatio-Temporal Representation Learning with Social Tie
    - \* 提出了一种用于个性化和连续 POI 推荐的统一时空神经网络框架 (PPR)
      - 利用用户的签到记录和社交关系, 通过联合嵌入和序列建模来推荐个性化 POI 用于查询用户
      - PPR 通过在异构图中联合建模 User-POI 关系、序列模式、地理影响和社会关系来学习用户和 POI 表示
      - 使用基于 LSTM 模型设计的时空神经网络对用户个性化序列模式进行建模用于个性化 POI 推荐

- \* 整体来说本文考虑 Sequential Effect, Geographical Influence, Social Influence 和 Temporal Influence
- Bi-LSTM
  - DeepAltTrip: Top-k Alternative Itineraries for Trip Recommendation
    - \* 为给定的出发点和目的地的用户推荐前 k 个备选的具有不同 POI 的行程。这些备选路线不仅是过去用户采用的流行路线，而且是彼此不同（多样化）的路线
    - \* DeepAltTrip 程序所包含的两个部分：
      - 行程网 (ITRNet)，通过使用图自动编码器和 bi-LSTM（前向和后向）来估计行程中 POI 的可能性
      - 路线生成程序，生成 K 个不同的行程，通过使用 ITRNet 获得的相关 POI，提出了 DeepAltTrip 的两种变体：基于 LSTM 的行程生成技术和基于采样的技术
    - \* 整体来说本文的模型主要考虑 Sequential Effect 和 Geographical Influence
- Modified LSTM
- Self-Attention
  - Spatial-Temporal Interval Aware Sequential POI Recommendation(STiSAN)
    - \* 该模型使用 TAPE(Time Aware Position Encoder) 和 IAAB(Interval Aware Attention Block) 以降低现有的 self-attention 机制的计算消耗
      - TAPE: 根据 POI 序列中的时间间隔动态调整位置之间的差异，并进一步反映相对时间接近度，主要考虑 temporal Influence
      - IAAB: 推动模型在 POI 之间附加重要的空间信息并提供更可解释的推荐，主要考虑 Geographical Influence
      - Target Aware Attention Decoder (TAAD): 用来改进用户对候选 POI 的偏好表示，主要考虑 Semantic Effect
  - TADSAM: A Time-Aware Dynamic Self-Attention Model for Next Point-of-Interest Recommendation(TADSAM)
    - \* 本文提出了一种时间感知动态自我注意模型 TADSAM 来预测用户未来的下一个决策活动
    - \* Extended Self-attention Layer: 是一种时间感知的 self-attention 模型来输入时间动态轨迹序列，这里考虑的是 Temporal Influence
    - \* Time Partten Layer: 考虑到时间的影响，将用户的签到记录分为不同的时间窗口，并开发了一种个性化的权重计算方法，以利用用户行为的时间模式
    - \* Next POI Prediction: 这里考虑地理因素和流行度 (Semantic Effect)
    - \* 总的来说本文还是主要考虑 Temporal Influence
  - Combining Non-sampling and Self-attention for Sequential Recommendation
    - \* 本文提出了一种结合了非采样机制和 self-attention 机制的非采样自注意顺序推荐 (NSSR) 模型

- \* 负抽样策略是指从用户没有交互过的数据中抽取负样本。核心思想是从所有训练样本中随机选择负实例条目，并在模型训练过程中最大化正负实例之间观察到的距离
- \* Self-attention network: 将交互序列作为当前用户表示，利用整个数据构建训练对，对模型进行全面训练，从而提高模型的推荐性能
- \* 个人感觉该模型最主要的影响因素是: Sequential Effect
- STAN: Spatio-Temporal Attention Network for Next Location Recommendation
  - \* STAN 明确利用轨迹上所有带有 self-attention 层的签到的相对时空信息，从而允许在非相邻位置和非连续签到之间进行点对点交互，并具有明确的时空效应
  - \* STAN 使用双层注意力架构，首先聚合用户轨迹内的时空相关性 (Self-Attention Aggregation Layer), 然后考虑个性化项目频率 (PIF) 召回目标 (Attention Matching Layer)
    - Self-Attention Aggregation Layer: 提出了一个扩展模块来考虑轨迹中两次访问之间的不同空间距离和时间间隔，以聚合相关的访问位置并更新每次访问的表示
    - Attention Matching Layer: 通过与用户轨迹的更新表示相匹配，从所有 L 个位置中召回最合理的候选者
  - \* 总的来说本文模型主要考虑用户轨迹的时空相关性 (Temporal Influence 和 Geographical Influence)，同时也考虑非相邻位置和非连续访问之间的相关性 (个人感觉是 Sequential Effect???)

### (3) GRU

- LightMove: A Lightweight Next-POI Recommendation for Taxicab Rooftop Advertising
  - 提出了一种轻量级但准确的基于深度学习的方法来预测出租车的下一个位置，以更好地准备基于地点的人口统计信息的有针对性的广告，本文设计了基于神经常微分方程 (NODEs) 的模型
  - 提出的模型由四个模块组成:
    - \* 一个有 attention 的短期历史模块
    - \* 一个没有 attention 的长期历史模块
    - \* 一个主神经常微分方程 (NODE) 层，从初始隐藏向量  $h(0)$  生成最后的隐藏向量  $h(1)$
    - \* 一个分类器，预测接下来的位置
  - NODE 层:
    - \* 连续的 GRU 单元
    - \* ODE 状态跳跃
    - \* 自适应参数生成
  - 本文主要考虑 Geographical Influence 和 Temporal Influence

### (4) Graph Embedding

- Modeling Spatio-temporal Neighbourhood for Personalized Point-of-interest Recommendation(STGCAN)
  - 将带有时间信息的 Knowledge Graph with temporal information(TKG)(包括带有时间戳的用户和位置) 引入 POI 推荐中, 并在此基础上提出了一种时空图卷积注意力网络 (STGCAN) 通过动态捕获时空邻域来学习用户对 TKG 偏好
  - 这里主要考虑 Geographical Influence, Temporal Influence, 和 Semantic Effect
  - Neighbour Aggregation Layer
    - \* 该层基于 TKG 上的时间信息, 将每个时间戳的用户和位置实体各自的邻域与构建的用户/位置接收域进行聚合
    - \* 这里的 User Neighbour 和 Location Neighbour 我个人认为是在 TKG 上使用卷积网络所寻找到的拥有相似偏好的个体从而建立相关性
- Learning Graph-based Disentangled Representations for Next POI Recommendation
  - 本文先构建 POI 的两个关系图 (基于距离的关系图和基于转移的关系图), 用图卷积和层聚合的操作提取 POI 的特征, 而后通过通过相对位置的 self-attention 扩展得到用户对 POI 的时空偏好, 最后通过 softmax 计算推荐列表
  - Graph-based Disentangled Representation Modeling
    - \* POI Relation Graph Construction: 采用两个全局 POI 关系图 (基于距离的关系图和基于转移的关系图) 来指导表示学习从而描述 POI 的内在特征
    - \* Disentangled Representation Propagation: 利用图卷积操作从 POI 关系图中提取有用信息以学习解耦的表示, 同时保持表示的不同组件独立
    - \* Representation Aggregation: 利用层聚合策略来组合来自不同层的表示
    - \* 个人认为这里的两个关系图是分别考虑 Geographical Influence 和 Semantic Effect
    - \* 这一部分大致上可以算作图操作
  - User Spatial-Temporal Preference Modeling
    - \* Personalized Spatial-Temporal Interval Encoding: 考虑到每个用户都有自己的签到偏好, 这里采用区间的相对长度来模拟  $S(u)$  内的空间和时间关系。明确地对 POI 之间的空间和时间关系进行建模, 以提高模型的有效性
    - \* Disentangled Self-Attention Aggregation: 为了捕捉签到序列的多级规律性, 本文提出了对相对位置的 self-attention 的扩展, 以将 POI 之间的不同关系合并到一个序列中, 在聚合过程中将每个组件分成一个单独的 attention-head, 然后将它们收集起来
    - \* User Preference Estimation: 使用 softmax 函数计算每个候选者的偏好分数, 从而估计用户对下一个访问的 POI 的偏好
    - \* 这一部分大致上考虑 Temporal Influence, Geographical Influence 和 Sequential Effect
- GETNext: Trajectory Flow Map Enhanced Transformer for Next POI Recommendation(GETNext)

- 本文的主干网络是 Transformer, 通过构建 POI 之间的转移权重图 (trajectory flow map) 并通过 GCN 进行 POI Embedding; 又同时预测 POI、时间、类别, 加强了损失函数
- trajectory flow map
  - \* 在轨迹流图上训练图神经网络 (GNN) 以生成 POI 嵌入, 该嵌入结合类别、位置、和 POI 的签到频率编码用户在每个 POI 上的通用运动模式
  - \* 一个 attention module, 以轨迹流图和节点特征的邻接矩阵为输入, 生成一个转移注意力图, 显式地模拟 POI 之间的转移概率
  - \* 该模块主要考虑 Geographical Influence 和 Semantic Effect
- Contextual Embedding Module(获得用户嵌入、POI 类别嵌入和时间编码)
  - \* 将相应轨迹中的用户嵌入和 POI 嵌入相结合, 以实现更好的个性化。
  - \* POI 类别嵌入和时间编码也相结合, 以捕捉用户对不同 POI 类别的时间偏好
  - \* 该模块主要考虑 Temporal Influence 和 Semantic Effect
- Hierarchical Multi-Task Graph Recurrent Network for Next POI Recommendation(HMT-GRN)
  - HMT-GRN 模型不仅可以更好的学习稀疏的用户-POI 关系, 同时采用减少搜索空间以提高效率
  - HMT-RN
    - \* Learning next POI and region distributions: 通过学习稀疏的 User-POI 矩阵以及具有较低数据稀疏性的 User-G@P 矩阵来更好地执行 next-POI 推荐任务。其中不仅预测 next-POI, 还预测 next-POI 所在的下一个区域 G@p
    - \* Hierarchical Beam Search: 不是单独的使用稀疏的 next-POI 任务分布进行预测, 而是利用学习到的 next-POI 和 G@P 任务分布, 通过计算所有任务的联合概率对来自 L 的 POI 的搜索空间进行排序, 并预测下一个 POI
    - \* Selectivity Layer: 为了在个性化和探索之间取得平衡, 提出了一个新颖的选择性层, 通过预测用户之前是否访问过 next-POI, 从而确定模型进行个性化或探索
    - \* 整体来说该部分主要考虑 Sequential Effect 和 Semantic Effect
  - Graph Recurrent Network:
    - \* 提出了 GRN 模块来替换 HMT-RN 模型中的 LSTM, 以允许额外学习全局 POI-POI 关系, 通过增加了循环结构和通过使用区域和时隙连接时空图中的 POI 来缓解数据稀疏性从而扩展了 Dimensional GAT (DGAT) 变体
    - \* 个人感觉这里还是主要考虑 Semantic Effect
- Attentive sequential model based on graph neural network for next poi recommendation (GNN model(图神经网络))
  - 将用户的签到行为表示为图, 并使用 GNN 来学习用户的行为模式和他们的偏好, 以图本地化的方式进行 next-POI 推荐

- ASGNN 大致上包含四个步骤:
  - \* 将用户的历史签到数据构建为有向图 (每个签到序列被建模为一个有向图)
  - \* 使用 GNN 通过探索用户和 POI 之间丰富的互动来模拟用户的偏好和 POI 的特征
  - \* 设计了一个两层个性化的注意力分层网络, 以获得用户对 POI 的个性化的长期和短期偏好
  - \* 最后使用 softmax 层来预测用户的下一步行为, 并推荐相应 POI
- 本文主要是通过学习用户的历史行为来捕捉其长短期偏好, 主要考虑 Semantic Effect
- DynaPosGNN: Dynamic-Positional GNN for Next POI Recommendation(GNN model)
  - 根据特定时间点预测用户对相应 POI 的访问, 而非简单地预测当前访问后去哪里
  - 使用多边图表示来考虑用户访问历史的动态。利用 POI 节点之间的多条边, 并将每次访问历史表示为不同的边
  - DynaPosGNN 通过分析到达时间与 “User-POI 图” 和 “POI-POI 图” 的两个空间动态图之间的相关性来预测用户的下一个位置
  - 整体上本文考虑 Sequential Effect, Geographical Influence, Semantic Effect 和 temporal Influence

#### (5) Matrix Factorization Models(矩阵分解模型)

- Leveraging social influence based on users activity centers for point-of-interest recommendation
  - 通过将社会、地理和时间信息整合到矩阵分解 (MF) 技术中来解决数据稀疏性对推荐系统建模的影响
  - 其中基于两个因素对社会影响进行建模: 用户之间在常见签到方面的相似性以及他们之间的友谊, 模型中的友谊算法基于用户的地理活动中心
  - 总的来说本文主要考虑了 Geographical Influence, Social Influence 和 Temporal Influence

#### (6) Hybrid Models(混合模型)

- Next Point-of-Interest Recommendation with Inferring Multi-step Future Preferences(CFPRec)
  - Past Preference Encoder
    - \* bidirectional Transformer
  - Current Preference Encoder
    - \* LSTM
  - Future Preference Extractor
    - \* two-layer attention aggregation
    - \* Intra-sequence Attention Aggregation

- \* Inter-sequence Attention Aggregation
  - 主要通过考虑 Semantic Effect，通过用户过去的偏好推导出多步骤的未来偏好从而模仿用户的行为
  - 同时强调 Sequential Effect，即用户访问的上下文序列对 next-POI 的影响
- Graph-Enhanced Spatial-Temporal Network for Next POI Recommendation
  - 借助图嵌入捕捉 POI 网络之间的高阶复杂地理影响 (而不仅仅是简单的考虑距离因素)，同时对用户的特定时间依赖进行建模 (LSTM)
  - Graph-Based Spatial Dependency Modeling(GSD)
    - \* 通过利用图嵌入来显式地建模复杂的地理影响
    - \* 从设计的 POI 语义图中捕获两种类型的地理影响，即基于距离和基于转移的影响
  - User-Specific Temporal Dependency Modeling
    - \* 基于 LSTM 的方法对时间依赖性进行建模
  - 整体来说本文的模型 (GSTN) 结合了用户的空间和时间依赖性，即主要考虑 Temporal Influence 和 Geographical Influence
- ST-PIL: Spatial-Temporal Periodic Interest Learning for Next Point-of-Interest Recommendation
  - ST-PIL 采用长短期兴趣学习的结构，充分利用时空上下文从历史签到中检索相关部分以进行周期性兴趣
  - 长期模块中，学习了每日粒度的时间周期兴趣，然后利用 intra-level attention 形成长期兴趣
  - 短期模块中，利用 LSTM 分别获取小时、区域和小时区域粒度的时空周期兴趣
  - 整体上看本文主要考虑 Semantic Effect 和时空因素 (Temporal Influence 和 Geographical Influence)
- SNPR: A Serendipity-Oriented Next POI Recommendation Model
  - 本文的模型主要推荐具有偶然性的 POI，而非推荐用户经常访问的 POI
  - 将定量的偶然性定义为在下一个 POI 推荐中对相关性和意外性的权衡
  - SNPR 的架构主要由四个部分组成：
    - \* 轨迹编码
    - \* 面向意外的建模 (Unexpectedness-oriented Modeling)
    - \* 面向相关性的建模
    - \* 偶然 POI 推荐和网络训练
  - 面向意外的建模 (Unexpectedness-oriented Modeling)
  - 面向相关性的建模 (Relevance-oriented Modeling):
    - \* Long-term preference modeling
    - \* Short-term preference modeling

- \* 整体来说相关性是依靠 LSTM 进行建模
  - 总的来说本文的偶然性是在满足用户的偏好的情况下为其推荐新的 POI, 故模型主要考虑 Semantic Effect
- You Are What and Where You Are: Graph Enhanced Attention Network for Explainable POI Recommendation
  - 以端到端的方式解释 POI 预测, 关注结构上下文、邻居影响、用户属性和地理位置影响四个因素
  - GEAPR 使用了三种不同的架构
    - \* 一个基于密集神经网络的结构性语境编码器被用来学习结构性语境 (Sequential Effect)
    - \* 一个基于图神经网络的注意力友谊编码器被用来模拟邻居的影响 (Social Influence)
    - \* 一个基于注意力的潜在因素化机被用来保存属性的相互作用 (Semantic Effect)
  - Geolocation encoding for users and POIs 考虑 Geographical Influence
- Out-of-Town Recommendation with Travel Intention Modeling
  - 设计了 TRAINOR: 全面捕捉用户的家乡偏好、用户从家乡到外地的兴趣漂移、外地地理影响和用户的旅行意图从而研究外地对用户的 POI 推荐问题
  - 本文模型的结构:
    - \* 设计了一个基于门控图神经网络 Gated Graph Neural Network (G-GNN) 的用户偏好表示模块, 以探索用户在家乡签到中编码的潜在结构信息
    - \* 通过注意力网络进行汇总后, 用户的家乡偏好通过非线性映射函数, 即多层感知器 multi-layer perceptron (MLP) 进一步转移到外地偏好。通过这种方式, 可以直接捕捉到从家乡到外地的兴趣漂移
    - \* 通过开发神经主题模型 Neural Topic Model (NTM) 和用户特定的旅行意向汇总, 设计了一个旅行意向发现模块
  - 本文综合考虑用户偏好、兴趣漂移、旅行意图和外地地理对模型的影响
  - 即本文主要考虑 Geographical Influence 和 Semantic Effect(属性影响)
- SAR-Net: A Scenario-Aware Ranking Network for Personalized Fair Recommendation in Hundreds of Travel Scenarios(我对这个模型有点拿不准, 暂时按其结构先归于混合模型)
  - 本文的模型是为访问不同场景的用户提供个性化的推荐服务
  - 提出了一种新颖的场景感知排名 网络 (SAR-Net)
    - \* 通过两个特定的注意力模块学习用户的跨场景兴趣, 从而从不同场景中获取丰富的数据, 这两个模块分别利用场景特征和项目特征来调制用户行为特征
    - \* 将前一模块的编码特征作为输入, 采用特定场景的线性变换层, 进一步提取特定场景的特征, 接着是两组 debias expert 网络, 即特定场景专家和场景共享专家。他们独立输出中间结果, 通过多场景门控模块进一步融合成最终结果



- \* 为了缓解人工干预造成的数据公平性问题, 提出了公平系数 (FC) 的概念来衡量单个样本的重要性, 并利用它来重新权衡 debias expert 网络中的预测

#### (7) next-POI Recommendation with nlp

- Conversation-Based Adaptive Relational Translation Method for Next POI Recommendation With Uncertain Check-Ins(CART)
  - 通过与用户进行对话 (即在 POI 推荐系统的基础上添加了一个对话模块), 从而整合即时用户偏好以获得更准确的 next-POI 推荐
  - 个人感觉这个模型算是比较另类的一个模型, 通过与用户对话逐步缩小 POI 推荐的范围以进行更好的推荐 (不过感觉让用户对 POI 搜索范围进行选择可能更常用一些)
  - 该模型包括离线训练阶段和在线训练阶段, 离线训练旨在在训练集上预训练推荐器和对话模块, 其中最大熵策略用于确定要询问的属性, 在线训练阶段, 通过训练集上的对话模块与用户模拟器交互, 对预训练的 CRS 进行优化
  - Recommender Module
    - \* 这是一种自适应关系翻译方法, 用于联合建模用户的历史顺序行为和对话
    - \* 历史顺序主要是考虑 Sequential Effect
  - Conversation Module
    - \* 寻求最佳的动作选择策略, 并以更少的对话次数获得成功的推荐
    - \* 个人认为这里主要考虑 Semantic Effect
- Translating Human Mobility Forecasting through Natural Language Generation
  - 将预测视为翻译问题, 并通过语言生成管道提出新的预测。旨在以序列到序列的方式将人类流动性预测问题作为语言翻译任务来解决 (可以看出主要是考虑 Sequential Effect)
  - Two-Branch Structure
    - \* 自然语言分支 (NL): 具有 sequence-to-sequence 结构的分支, 是 SHIFT 翻译输入提示生成输出句子的主要分支, 用来实现序列到序列的结构来”翻译”移动性描述
    - \* 辅助移动性分支 (Mob): 一个辅助分支, 用于加强 SHIFT 学习移动模式进行预测的能力, 进一步提高主分支生成移动性预测的能力
- Joint Spatio-Textual Reasoning for Answering Tourism Questions
  - 本文是 POI 推荐的衍生, 利用发帖问题中对 POI 的约束为用户推荐其所需的 POI
  - 联合空间文本推理模型, 将地理空间知识与文本语料库中的信息相结合来回答需要推荐 POI 的问题
  - 其中 POI 推荐网络是一个模块化的空间推理网络, 使用问题中提到的位置名称的地理坐标, 以及候选答案实体的地理坐标, 只对空间约束进行推理。将上下文距离权重与问题中提到的每个地点联系起来—这些权重将候选答案与它们各自的空间距离结合起来, 为 POI 生成一个”空间相关性”分数

- 这里除了考虑用户问题所提到的约束条件外，还考虑了时空因素对 POI 推荐的影响 (Geographical Influence 和 Temporal Influence)
- Answering POI-Recommendation Questions using Tourism Reviews
  - 采用问答方式 (QA) 从而回答兴趣点 (POI) 推荐问题 (使用描述 POI 的评论集来回答 POI 推荐的问题)
  - 本文的模型使用了一个三阶段的聚类-选择-排序架构
    - \* 对每个实体的文本进行聚类，以确定描述实体的典范句子
    - \* 使用一个神经信息检索 (IR) 模块，从大量的候选集合中选择一组潜在的实体
    - \* 使用一个具有更深层次的基于注意力的架构的检索器，从所选实体中挑选出最佳答案
  - 本文的模型主要考虑旅游论坛的评论集所提供的数据 (包括发帖日期和帖子中对 POI 的评论等)，整体来说我认为本文的模型主要考虑 Semantic Effect
- Point-of-Interest Type Prediction using Text and Images
  - 本文是通过发帖的信息对 POI 进行推荐，与以往只分析文本的模型不同，本文的模型同样考虑了帖子中图像对 POI 推荐的影响
  - 提出了一个多模态模型，该模型将文本和图像组合在两个层次上使用：
    - \* 模态门来控制文本和图像所需的信息量
    - \* 一种用于学习跨模式交互的交叉注意机制
  - 个人认为本文是通过分析帖子的文本和图片以寻找 Semantic Effect

#### (8) tensor factorization model

- Time-sensitive POI Recommendation by Tensor Completion with Side Information
  - 利用张量模型将观察到的 user-item-time 张量分解为 users, items and times 的低秩嵌入矩阵，对用户，POI 和时间间隔之间的三元交互进行建模
  - 提出了基于 social Hausdorff 距离的损失函数的反向传播公式，使模型能够利用社交图和 POI 位置来规范张量补全公式，即用 social Hausdorff 来计算 user-POI-time 的交互概率
  - 本文主要考虑 Geographical Influence, Social Influence, Temporal Influence

#### (9) DNN model

- Research on Personalized Minority Tourist Route Recommendation Algorithm Based on Deep Learning
  - 该模型属于是对特殊群体的 POI 推荐模型，利用对少数民族旅游需求群体兴趣点的个性化挖掘，提取社交网络中的客户数据特征，构建有趣的话题因素、地理位置因素、用户访问频率因素等数据特征
  - 将 DNN 网络与 LDA topic 模型和矩阵因子化算法相结合，并利用词嵌入技术将社交网络中的用户偏好特征、地理因素特征和概率主题特征被整合到少数民族旅游线路推荐任务中，通过神经网络学习特征间的高层互动，然后向用户做出个性化推荐

- 本文主要考虑 Geographical Influence 和 Semantic Effect

#### (10) Context-aware model

- Context-aware POI Recommendation using Neutrosophic Set for Mobile Edge Computing
  - 将 POI 推荐转换为基于 neutrosophic set (NS) 的上下文多属性决策问题, 适用于表示模糊决策信息, 通过多属性的 NS 聚合为用户推荐最符合其偏好的 POI
  - 本文是将地理位置、兴趣主题、受欢迎程度和社会关系四个属性结合以构建 POI 推荐的模型
  - 主要考虑 Social Influence, Geographical Influence 和 Semantic Effect
  - 不过该方法可以通过增加单属性的 NS 进行扩展, 因而并不局限于以上一个属性

#### (11) bi-transformer

- Pre-training Context and Time Aware Location Embeddings from Spatial-Temporal Trajectories for User Next Location Prediction
  - CTLE:
    - \* the encoding layer: 将时间编码向量与位置的编码向量融合, 从相对访问时间差中提取信息
    - \* the bidirectional Transformer encoder: 作为一个映射函数, 用于计算目标位置的嵌入, 给定其特定的上下文 neighbor
    - \* the pre-training objective: 通过对目标位置和上下文之间的共现概率以及对目标的绝对访问时间进行建模, 将位置的特征信息纳入其嵌入中
  - 本文主要的影响是: Geographical Influence 和 Temporal Influence

#### (12) auto-correlation model

- Next Point-of-Interest Recommendation with Auto-Correlation Enhanced Multi-Modal Transformer Network(AutoMTN)
  - Auto-Correlation Layer
    - \* 利用自相关机制通过子序列关系来扩展信息利用。即自相关通过计算子序列的自相关来发现子序列的依赖关系, 并通过时间延迟聚合来聚合相似的子序列
    - \* Dependencies of Sub-sequences
    - \* Time Delay Aggregation
    - \* 个人认为该层主要是考虑 Sequential Effect 和 Temporal Influence
  - Cross-Modal Auto-Correlation Layer
    - \* 设计了跨模态自相关, 使一种模态能够从另一种模态接收信息, 即 POI 和类别序列相互获取辅助信息
    - \* 该层仍然考虑 Sequential Effect

#### (13) online model

- Online POI Recommendation: Learning Dynamic Geo-Human Interactions in Streams
  - 本文的交互强化学习框架包括两个主要模块：
    - \* 表示模块: 表示模块是为了学习和跟踪用户和地理空间环境的状态表示
    - \* 模仿模块: 模仿模块是利用用户和地理空间环境的表征作为状态，将推荐的 POI 作为行动，以模仿用户的访问行为
  - 基本思想是将强化学习代理视为一个推荐者，并将强化学习环境视为用户和地理空间环境（如 POI、POI 类别和功能区）的联合组成，对人与人、地理与人、地理与地理的互动进行建模
  - 总的来说本文主要考虑: Geographical Influence, Semantic, Effect(属性影响), Social Influence 和 Temporal Influence

#### (14) Federated Learning model

- FedPOIRec: Privacy Preserving Federated POI Recommendation with Social Influence
  - 在联邦学习环境中调整了两个推荐模型：一个是用贝叶斯个性化排名（BPR）优化的传统矩阵分解模型，一个是基于卷积神经网络的顺序推荐器（CASER）
  - 本文中的模型为减少客户端的计算消耗，在全局模型生成后，使用 FHE 结构在朋友之间融合所学参数，即考虑用户朋友的偏好具有相似性
  - 本文的模型主要考虑 Social Influence，同时也考虑 Geographical Influence 和 Temporal Influence 对模型的影响

#### (15) Meta-Learning model

- Curriculum Meta-Learning for Next POI Recommendation
  - 本文探索了城市之间转移 next-POI 的推荐，将模型数据从具有丰富数据的多个城市转移到具有稀缺数据的冷启动城市，从而更好的解决 POI 推荐的冷启动问题
  - 提出了一个新的课程硬度感知元学习（CHAML）框架，通过将元学习和非均匀抽样策略纳入下一个 POI 搜索推荐中来缓解数据稀少和样本多样性问题
  - 本文不是一个典型的 POI 推荐问题而更像是一个数据转移问题，因此目前所列的模型的影响因素并不适用于该文章
- PREMERE: Meta-Reweighting via Self-Ensembling for Point-of-Interest Recommendation
  - 有关 PREMERE:
    - \* 是一种基于元学习的新型 POI 推荐样本重加权方案
    - \* 元模型架构 PREMERE-NET 被扩展为使用精心设计的上下文数据和处理正样本的单独流程
    - \* 元数据的缺失通过时间集成的自生成技术得到了了解
    - \* 将 PREMERE 整合到基于 DNN 的 POI 推荐算法中
  - 本文主要是考虑 spatial influence, social influence 和 temporal influence

- MFNP: A Meta-optimized Model for Few-shot Next POI Recommendation
  - 本模型主要是针对签到记录很少的冷启动用户推荐 next-POI
  - MFNP 模型的整体架构:
    - \* 将每个用户的签到序列拆分为支持集和查询集
    - \* 在使用元参数初始化本地参数后, 通过基本推荐系统对用户的偏好进行建模。在用户特定偏好建模模块中, 根据用户的个人签到记录使用地理详细的 LSTM 对用户的区域无关偏好进行建模 (虽然有 LSTM, 不过个人认为其主要结构还是元学习模型)
    - \* 在特定区域偏好建模模块中, 首先定位用户所属的相应用户组。然后从特定区域的签到中学习区域相关的人群偏好, 并通过时间和空间上下文将它们合并
    - \* 使用支持集在本地训练推荐系统, 并使用查询集全局更新元参数
  - 本文主要是考虑用户与区域的偏好以及时空因素, 即 Geographical Influence, Semantic Effect 和 Temporal Influence

#### (16) test collection of POI

- POINTREC: A Test Collection for Narrative-driven Point of Interest Recommendation
  - 本文并不是一个 POI 推荐模型, 而是一个 POI 集合
  - POINTREC 与其他测试集合之间的主要区别:
    - \* POINTREC 集合中的信息需求上下文和用户偏好均以自然语言详细描述, 并已沿多个维度进行人工注释
    - \* POINTREC 的集合不包括过去的用户历史记录 (除非在描述中引用了以前的经验), 从而使其成为冷启动问题。
    - \* POINTREC 的 POI 集合覆盖 23 个国家/地区, 其所覆盖范围较广

## 2. POI 模型的影响因素

### (1) 对影响因素进行分类

- Sequential Effect(顺序影响; 序列影响)
- Geographical Influence
- Semantic Effect(属性影响)
- Social Influence
- Temporal Influence